

Veri Madenciliği ve Makine Öğrenmesi Algoritmaları

Veri Mad. – Hafta 7

Bu hafta, dersin ikinci ana modülüne geçiş yapılarak Makine Öğrenmesi (MÖ) dünyasına giriş yapılacaktır.

MÖ'nin tanımı, klasik programlamadan farkları ve temel öğrenme türleri detaylıca ele alınacaktır.

Öğrenciler, bir MÖ projesinin yaşam döngüsünü ve temel terminolojiyi öğreneceklerdir.



Makine Öğrenmesinin Tanımı ve Kapsamı

Makine Öğrenmesi teriminin orijinali İngilizce 'Machine Learning'dir. Türkçede yaygın olarak makine öğrenmesi veya yapay öğrenme şeklinde kullanılır. MÖ, insan öğrenmesini taklit edebilen her türlü öğrenmeye verilen addır.

Makine Öğrenmesi ve Yapay Zeka İlişkisi

Makine öğrenmesi (MÖ), yapay zekânın (YZ) bir alt alanı olarak konumlanır. YZ'nin kullanıldığı hemen hemen her alanda, MÖ algoritmaları aktif olarak devreye girer.

MÖ'nün alt alanlarından biri ise Derin Öğrenme (Deep Learning) olarak bilinir, bu alan daha karmaşık modellerle çalışır.

Yapay Zeka, geniş bir şemsiye terimdir; MÖ ise bu zekayı elde etmenin bir yöntemidir.



Makine Öğrenmesine Duyulan İhtiyaç

Geleneksel programlama yöntemlerinin, bazı karmaşık görevlerde yetersiz kalması MÖ'yü zorunlu kılmıştır.

Örneğin, milyonlarca veriyi içeren görüntü veya doğal dil işleme gibi alanlarda kural tabanlı sistemler kurmak imkansızdır.

MÖ, dinamik, değişken ve büyük veri setlerinden otomatik olarak bilgi çıkarma yeteneği sunar.



Klasik Programlama Nasıl Çalışır?

Klasik programlamada programcılar, tüm olası durumları önceden analiz ederler.

Bu analiz sonucunda 'eğer-ise' mantığına dayanan koşullu ifadeler (kurallar) yazılır.

Programlar, bu kodlanmış kurallar doğrultusunda veriyi işler ve kesin bir çıktı (sonuç) üretir.

Akış şeması: Veri + Kurallar = Çıktı.



Makine Öğrenmesi Nasıl Çalışır?

Makine öğrenmesinde ise, sisteme hem veri hem de bu veriye ait doğru çıktılar (cevaplar) verilir.

MÖ algoritmaları, bu veri ve çıktılar arasındaki olası bağlantıları, ilişkileri ve şablonları keşfeder.

Böylece sistem, bu ilişkileri formülize eden bir 'kural seti' (model) ortaya çıkarır.

Akış şeması: Veri + Çıktı = Kurallar (Model).



Klasik Programlama vs. Makine Öğrenmesi Özeti

Klasik Programlama:

Girdiler: Veri ve Kurallar.

Çıktı: Cevap.

Odak: Prosedürleri açıkça tanımlamak.

Esneklik: Düşük, yeni durumlara uyum zor.

Makine Öğrenmesi:

Girdiler: Veri ve Cevap.

Çıktı: Kurallar (Model).

Odak: Verideki örüntüleri otomatik olarak bulmak.

Esneklik: Yüksek, yeni verilerle kendini geliştirme yeteneği.



Makine Öğrenmesinin Uygulama Alanları

Tıbbi teşhis ve görüntü analizi.
Finansta dolandırıcılık tespiti ve hisse senedi tahmini.
Doğal Dil İşleme (NLP) ile metin çevirisi ve duygu analizi.
Otonom araçlar ve robotik sistemler.
Öneri sistemleri (e-ticaret ve medya platformları).

Makine Öğrenmesinin Temel Terminolojisi

Bir MÖ projesini anlamak için temel terimlerin bilinmesi şarttır.
Bu terimler, bağımlı/bağımsız değişkenler, model, eğitim/test verisi ve özellik (feature) gibi kavramları içerir.
Doğru terminoloji kullanımı, projeler arası iletişimi ve anlaşılabilirliği artırır.

Bağımsız Değişken (Özellik / Feature)

Bağımsız değişkenler, girdi olarak kullanılan, tahmini etkileyen özelliklerdir. Bunlara genellikle 'özellik' (feature) adı verilir. Örneğin, bir evin fiyatını tahmin ederken evin metrekaresi, oda sayısı, yaşı gibi veriler bağımsız değişkenlerdir. Model, bu özelliklere bakarak öğrenir.

Bağımlı Değişken (Hedef / Target)

Bağımlı değişken (Target variable), modelin öğrenmeye veya tahmin etmeye çalıştığı sonuçtur.

Bu, bir sınıf etiketi (kedi/köpek) veya sürekli bir değer (fiyat) olabilir.

Örneğin, evin fiyatının kendisi bağımlı değişkendir.

Modelin başarısı, bağımlı değişkeni ne kadar doğru tahmin ettiğine bağlıdır.

Model Kavramı

Model, algoritmanın eğitim verisinden öğrenerek oluşturduğu matematiksel veya istatistiksel yapıdır.

Model, girdi (bağımsız değişken) ile çıktı (bağımlı değişken) arasındaki ilişkiyi temsil eden fonksiyon setidir.

Eğitim süreci tamamlandığında, yeni ve bilinmeyen verilere tahmin üretmek için bu model kullanılır.

Eğitim Verisi (Training Data)

Eğitim verisi, MÖ modelinin parametrelerini öğrenmek için kullanılan büyük veri setidir.

Bu veriler, denetimli öğrenme durumunda hem özellikleri hem de doğru etiketleri içerir.

Model, eğitim verisi üzerindeki örüntüleri tekrarlayarak genelleme yapmayı öğrenir.



Test Verisi (Test Data)

Test verisi, modelin eğitim sırasında görmediği, tamamen yeni bir veri setidir. Bu veri, modelin yeni durumlara ne kadar genelleme yapabildiğini ve gerçek dünyada ne kadar başarılı olacağını ölçmek için kullanılır. Modelin test verisindeki başarısı, onun gerçek performansını gösterir.

Doğrulama Verisi (Validation Data)

Bazen model seçimi veya hiperparametre ayarlaması için ek bir veri setine ihtiyaç duyulur: Doğrulama verisi.

Doğrulama verisi, modelin eğitimi optimize etmek ve aşırı uydurma (overfitting) sorununu azaltmak için kullanılır.

Eğitim, doğrulama ve test setlerinin doğru ayrılması, projenin objektifliğini sağlar.



Aşırı Uydurma (Overfitting) Nedir?

Overfitting, modelin eğitim verisini çok iyi öğrenmesi, hatta ezberlemesi ancak test verisinde kötü performans göstermesidir.

Bu durumda model, eğitim verisindeki gürültüyü ve istisnaları da kural olarak kabul eder.

Sonuç: Yüksek eğitim doğruluğu, düşük genelleme yeteneği.



Yetersiz Uydurma (Underfitting) Nedir?

Underfitting, modelin eğitim verisindeki temel örüntüleri bile öğrenemeyecek kadar basit kalmasıdır.

Bu durum genellikle modelin yetersiz karmaşıklıkta olmasından veya yetersiz eğitim süresinden kaynaklanır.

Sonuç: Hem eğitim hem de test setinde düşük doğruluk.

Makine Öğrenmesi Türlerine Giriş

Makine öğrenmesi algoritmaları, öğrenme yöntemlerine göre üç ana kategoriye ayrılır:

1. Denetimli (Supervised) Öğrenme.
2. Denetimsiz (Unsupervised) Öğrenme.
3. Pekiştirmeli (Reinforcement) Öğrenme.



1. Denetimli (Gözetimli) Öğrenme

Denetimli öğrenme, veriden çıktıları elde edecek fonksiyonları, kuralları veya şablonları bulmak için kullanılır.

Kullanılan veri setinde sınıflara ait etiket (label) veya sonuç değeri (target value) bulunur.

Modelin amacı, girdi ve çıktı arasındaki haritalamayı (mapping) öğrenmektir.

Denetimli Öğrenmenin Alt Alanları

Denetimli öğrenme iki temel problem türü için kullanılır:

1. Sınıflandırma (Classification): Çıktının kategorik (ayrık) olduğu durumlar.
2. Kestirim/Regresyon (Regression): Çıktının sürekli (sayısal) bir değer olduğu durumlar.

Sınıflandırma (Classification)

Sınıflandırma, bir girdi verisinin hangi kategoriye (sınıfa) ait olduğunu tahmin etme işlemidir.

Örnekler: E-postanın spam olup olmadığı, tümörün iyi huylu mu kötü huylu mu olduğu, bir resimde hangi hayvanın bulunduğu.

Çıktı, ayırık ve önceden tanımlanmış sınıflardan biridir.

İkili Sınıflandırma (Binary Classification)

Bu, en basit sınıflandırma türüdür ve çıktının sadece iki olası değeri (örneğin 0 veya 1, Evet veya Hayır) olduğu durumdur.

Örnek: İstenmeyen e-posta (spam) filtreleme işlemi bir ikili sınıflandırma problemidir.

Diğer örnekler: Kredi başvurusu onayı (Kabul/Red), Müşteri kaybı tahmini (Churn/Non-churn).

Çoklu Sınıflandırma (Multi-class Classification)

Girdinin ikiden fazla potansiyel sınıfa atanması gerektiği durumlardır.

Örnek: Bir el yazısı tanıma sisteminde, harflerin (A'dan Z'ye) her biri ayrı bir sınıftır.

Diğer örnekler: Hava durumu tahmini (Güneşli, Bulutlu, Yağmurlu, Karlı), Görüntüdeki nesne tanıma (Kedi, Köpek, Kuş, Araba).

Sınıflandırma Algoritmaları – Karar Ağaçları

Karar Ağaçları (Decision Trees), veriyi dallanma yapılarıyla bölerek nihai karara ulaşan algoritmalardır.

Avantajları: Yorumlanabilirliklerinin yüksek olması ve ölçeklendirmeye gerek duymamaları.

Dezavantajları: Tek bir ağaç aşırı uydurmaya eğilimli olabilir.

Sınıflandırma Algoritmaları – Destek Vektör Makineleri (SVM)

SVM'ler, farklı sınıflara ait veri noktalarını en geniş boşlukla (margin) ayıran bir hiper düzlem bulmayı hedefler.

Özellikle yüksek boyutlu verilerde ve karmaşık sınırları ayırmada etkilidir.

Kernel trick (çekirdek hilesi) sayesinde doğrusal olarak ayıramayan verileri bile işleyebilir.

Sınıflandırma Metrikleri: Doğruluk (Accuracy)

Doğruluk, doğru tahmin edilen örnek sayısının toplam örnek sayısına oranıdır.
Formül: $(\text{Doğru Pozitif} + \text{Doğru Negatif}) / \text{Toplam}$.
Basit ve anlaşılır bir metriktir, ancak dengesiz veri setlerinde (imbalanced data) yanıltıcı olabilir.

Sınıflandırma Metrikleri: Hata Matrisi (Confusion Matrix)

Hata Matrisi, modelin her bir sınıfta ne kadar başarılı veya hatalı olduğunu gösteren tablo yapısıdır.

Dört temel bileşeni vardır: TP (Doğru Pozitif), TN (Doğru Negatif), FP (Yanlış Pozitif), FN (Yanlış Negatif).

Özellikle hassas kararlar gerektiren alanlarda (tıpta) hayati önem taşır.

Sınıflandırma Metrikleri: Kesinlik (Precision) ve Geri Çağırma (Recall)

Kesinlik (Precision): Model pozitif dediğinde, bunun ne kadarının gerçekten pozitif olduğunu ölçer (FP'yi cezalandırır).

Geri Çağırma (Recall): Gerçekte pozitif olan durumların ne kadarını modelin doğru yakaladığını ölçer (FN'yi cezalandırır).

Bu metrikler, problem türüne göre optimize edilmelidir (Örneğin spam filtrelemede Kesinlik önemlidir, hastalık tespitinde Geri Çağırma).



Kestirim (Regresyon)

Regresyon, bağımlı değişkenin sürekli ve sayısal olduğu tahmin problemlerini ifade eder.

Modelin amacı, girdiler ve çıktılar arasındaki en uygun çizgiyi (fonksiyonu) bularak gelecekteki bir değeri tahmin etmektir.

Örnekler: Ev fiyatı tahmini, sıcaklık tahmini, bir hissenin gelecekteki değeri.

Regresyon Algoritmaları – Doğrusal Regresyon

Doğrusal Regresyon (Linear Regression), bağımlı değişken ile bir veya daha fazla bağımsız değişken arasında doğrusal bir ilişki kurar. Model, veri noktalarına en yakın olan düz çizgiyi bulmaya çalışır. Basit, hızlı ve yorumlanabilirlik açısından güçlü bir başlangıç modelidir.



Regresyon Algoritmaları – Polynomial Regresyon

Veri noktaları doğrusal bir ilişki sergilemediğinde, Polynomial Regresyon kullanılır.

Bu yöntem, modelin daha karmaşık, eğrisel ilişkileri yakalamasına olanak tanır. Ancak yüksek dereceli polinomlar kullanmak aşırı uydurma riskini artırır.



Regresyon Metrikleri: Ortalama Mutlak Hata (MAE)

Ortalama Mutlak Hata (Mean Absolute Error - MAE), gerçek değer ile tahmin edilen değer arasındaki mutlak farkların ortalamasıdır.
Avantajı: Hata birimi, tahmin edilen değer birimiyle aynıdır ve büyük sapmalara karşı daha az hassastır (robust).

Regresyon Metrikleri: Ortalama Karesel Hata (MSE)

Ortalama Karesel Hata (Mean Squared Error – MSE), farkların karesinin ortalamasıdır.

Avantajı: Büyük hataları daha çok cezalandırır, bu da modelin büyük sapmalardan kaçınmaya odaklanmasını sağlar.

Dezavantajı: Hata birimi, orijinal birimin karesidir, bu da yorumlamayı zorlaştırabilir.



Regresyon Metrikleri: Kareseel Ortalamannn K    (RMSE)

Kareseel Ortalamannn K    (Root Mean Squared Error – RMSE), MSE'nin karek   d  r.

RMSE, MSE'nin b  y  k hataları cezalandırma   zelliđini korur ancak sonucu orijinal birim cinsinden verir.

Regresyon modellerinin performansını karđılařtırmada en yaygın kullanılan metriktir.



2. Denetimsiz (Gözetimsiz) Öğrenme

Denetimsiz öğrenme, algoritmanın etiketlenmemiş (çıktı değeri olmayan) veri setlerinde gizli yapıları ve örüntüleri kendiliğinden bulmasını hedefler.

Modelin amacı, veri içindeki benzerliklere göre gruplama yapmak veya verinin yapısını basitleştirmektir.

Temel olarak Kümeleme (Clustering) ve Boyut Azaltma (Dimensionality Reduction) problemleri için kullanılır.



Denetimsiz Öğrenme Uygulamaları

Müşteri Segmentasyonu: Pazardaki müşterileri benzer davranışlara göre gruplama.

Anomali (Aykırı Değer) Tespiti: Veri setindeki normalden sapan nadir olayları bulma (örneğin siber güvenlikte saldırı tespiti).

Boyut Azaltma: Büyük veri kümelerinin daha az değişkenle temsil edilmesi.



Kümeleme (Clustering)

Kümeleme, benzer özelliklere sahip veri noktalarını otomatik olarak gruplara ayırma sürecidir.
Gruplar (kümeler) içinde benzerlik yüksek, gruplar arasında benzerlik düşüktür.
K-Means, bu alandaki en bilinen ve temel algoritmadır.

Kümeleme Algoritması: K-Means

K-Means algoritması, veri setini önceden belirlenmiş K adet kümeye ayırır. Her kümenin bir merkezi (centroid) vardır. Algoritma, veri noktalarını, en yakın küme merkezine atayarak iteratif bir süreçle merkezleri optimize eder.



Boyut Azaltma (Dimensionality Reduction)

Boyut azaltma, veri setindeki değişken (özellik) sayısını önemli bilgiyi kaybetmeden düşürme işlemidir.

Amaç, hesaplama karmaşıklığını azaltmak, görselleştirmeyi kolaylaştırmak ve aşırı uydurmayı engellemektir.

Temel Bileşen Analizi (Principal Component Analysis - PCA), bu alanda en sık kullanılan tekniktir.



3. Pekiştirmeli (Reinforcement) Öğrenme

Pekiştirmeli öğrenme (RL), bir ajanın belirli bir ortamda, deneme-yanılma yoluyla öğrenmesini temel alır.

Ajan, attığı adımların sonucunda aldığı ödülleri (reward) maksimize etmeye çalışır.

RL, denetimli ve denetimsiz öğrenmeden farklı olarak, doğrudan etiket veya veri setine ihtiyaç duymaz, kendi verisini ortamla etkileşime girerek üretir.



Pekiştirmeli Öğrenmenin Temel Kavramları

Ajan (Agent): Karar veren ve eylem gerçekleştiren varlık.

Ortam (Environment): Ajanın etkileşimde bulunduğu dünya (örneğin bir oyun veya fiziksel dünya).

Durum (State): Ortamın o andaki durumu.

Eylem (Action): Ajanın bir durumdayken yapmayı seçtiği şey.

Ödül (Reward): Bir eylemin sonucunda ajana verilen geribildirim (pozitif veya negatif).



Pekiştirmeli Öğrenme Uygulamaları

Robotik: Robotların karmaşık görevleri öğrenmesi (yürüme, nesne manipülasyonu).

Oyun Teorisi: AlphaGo gibi yapay zeka sistemlerinin insanları stratejik oyunlarda yenmesi.

Finansal Ticaret: Optimal alım/satım kararlarını saptama.

Kaynak Yönetimi: Enerji şebekelerinin veya trafik akışlarının optimize edilmesi.



Makine Öğrenmesi Projesinin Yaşam Döngüsü

Bir MÖ projesi sistematik adımlarla ilerler:

1. Problem Tanımlama.
2. Veri Toplama ve Anlama.
3. Veri Hazırlama ve Ön İşleme.
4. Model Seçimi ve Eğitimi.
5. Model Değerlendirme.
6. Modelin Dağıtımı ve İzlenmesi.

Yaşam Döngüsü 1. Adım: Problem Tanımlama

Bu aşamada, projenin iş hedefleri ve makine öğrenmesi açısından çözülecek problem netleştirilir.

Problemin denetimli (sınıflandırma mı, regresyon mu?) yoksa denetimsiz mi olduğuna karar verilir.

Başarı metrikleri (RMSE, Doğruluk vb.) bu aşamada belirlenmelidir.

Yaşam Döngüsü 2. Adım: Veri Toplama ve Anlama

Modeli eğitmek için gerekli olan veri setleri toplanır.
Veri kaynaklarının güvenilirliği ve etiketleme kalitesi incelenir.
Veri yapısı (boyutu, değişken tipleri, eksik değerler) keşifsel veri analizi (EDA) ile anlaşılır.



Yaşam Döngüsü 3. Adım: Veri Hazırlama (Pre-processing)

Bu aşama, MÖ projesinin en zaman alıcı kısmıdır.
Eksik değerlerin doldurulması (imputation) veya silinmesi.
Aykırı değerlerin (outliers) tespiti ve yönetimi.
Verinin ölçeklendirilmesi (scaling) ve normalleştirilmesi (normalization).
Kategorik verilerin sayısal formata dönüştürülmesi (one-hot encoding).

Ön İşleme: Özellik Mühendisliği (Feature Engineering)

Özellik Mühendisliği, mevcut verilerden yeni ve daha anlamlı bağımsız değişkenler üretme sanatıdır.

Örneğin, doğum tarihi bilgisinden yaş veya hafta içi/hafta sonu bilgisini çıkarmak.

Başarılı özellikler, modelin öğrenme yeteneğini doğrudan artırır.

Yaşam Döngüsü 4. Adım: Model Seçimi ve Eğitimi

Problemin türüne (regresyon/sınıflandırma) uygun bir veya birden fazla algoritma seçilir.

Seçilen algoritmalar eğitim verisi üzerinde çalıştırılır.

Modelin performansını etkileyen hiperparametreler optimize edilir (Örneğin, öğrenme oranı, ağaç derinliği).



Yaşam Döngüsü 5. Adım: Model Değerlendirme

Eğitilmiş model, daha önce görmediği test verisine tahminler üretir. Bu tahminler, ilk adımda belirlenen metrikler (Doğruluk, RMSE, F1 Skoru vb.) kullanılarak değerlendirilir. Aşırı uydurma veya yetersiz uydurma durumları kontrol edilir ve gerekirse önceki adımlara geri dönülür.



Yaşam Döngüsü 6. Adım: Dağıtım (Deployment)

Başarılı bulunan model, gerçek dünya uygulamalarında kullanılmak üzere dağıtım (deployment) ortamına alınır.
Bu, modelin bir web servisi (API) olarak sunulması veya bir cihaza gömülmesi anlamına gelebilir.
Modelin dağıtılması, MÖ'nün iş değerini sağladığı son aşamadır.



Yaşam Döngüsü 7. Adım: İzleme ve Bakım (Monitoring)

Model üretim ortamında çalışırken performansı sürekli olarak izlenmelidir. Veri kayması (data drift) veya model bozulması (model decay) gibi durumlar zamanla performans düşüşüne neden olabilir. Performans düştüğünde, modelin yeniden eğitilmesi (retraining) gerekebilir.



Denetimli Öğrenme: İleri Konular

Topluluk Öğrenme, tek bir model yerine birden fazla modelin tahminlerini birleştirerek daha güçlü ve kararlı tahminler elde etme yöntemidir. Temel tipleri: Bagging (Rastgele Ormanlar), Boosting (Gradient Boosting) ve Stacking. Bu yöntemler, genellikle tekil algoritmalarından daha yüksek doğruluk sağlar.

Topluluk Öğrenme Algoritmaları: Rastgele Ormanlar (Random Forests)

Rastgele Ormanlar, birden çok karar ağacını (forest) eğiterek bunların oylarını birleştirir.

Her ağaç, verinin rastgele bir alt kümesi ve özelliklerin rastgele bir alt kümesi üzerinde eğitilir.

Bu, aşırı uydurmayı azaltır ve genelleme yeteneğini artırır.

Topluluk Öğrenme Algoritmaları: Gradyan Artırma (Gradient Boosting)

Gradient Boosting, birbirini takip eden modellerin, önceki modelin yaptığı hataları düzelterek öğrenmesini sağlar.

Her yeni model, önceki modelin 'artıklarını' (residuals) minimize etmeye odaklanır.

XGBoost ve LightGBM gibi popüler uygulamaları bulunmaktadır.

Özel Öğrenme Türü: Yarı-Denetimli Öğrenme

Yarı-Denetimli Öğrenme (Semi-Supervised Learning), hem küçük miktarda etiketli veri hem de büyük miktarda etiketsiz veri kullanır. Etiketleme maliyetinin çok yüksek olduğu durumlarda etiketsiz veriden yapısal bilgi elde etmek için kullanılır. Özellikle büyük ölçekli veri setlerinde etkilidir.

Özel Öğrenme Türü: Kendiliğinden Denetimli Öğrenme

Kendiliğinden Denetimli Öğrenme (Self-Supervised Learning - SSL), etiketsiz veriyi alıp, verinin kendisinden görevler (pseudo-labels) oluşturur. Model, bu yapay görevleri çözmeyi öğrenerek verinin derin özelliklerini çıkarır. Özellikle büyük dil modellerinin (LLM) eğitiminde öncül öğrenme aşaması olarak kullanılır.



Veri Türleri ve MÖ İlişkisi: Yapısal Veri

Yapısal veri (Structured Data), ilişkisel veritabanları veya tablolar halinde organize edilmiş, tanımlanmış formatlara sahip veridir.
Örnekler: Müşteri bilgileri, finansal işlem kayıtları, anket sonuçları.
Bu tür veriler genellikle geleneksel regresyon, sınıflandırma ve karar ağaçları algoritmaları için idealdir.



Veri Türleri ve MÖ İlişkisi: Yapısal Olmayan Veri

Yapısal olmayan veri (Unstructured Data), önceden tanımlanmış bir formata sahip olmayan, düzensiz veridir.

Örnekler: Sosyal medya yorumları, kamera görüntüleri, konuşma kayıtları. Bu tür veriler genellikle Derin Öğrenme (Deep Learning) modelleri ve sinir ağları gerektirir.



Model Karmaşıklığı ve Hesaplama Kaynakları

Model karmaşıklığı arttıkça (örneğin derin sinir ağıları), genellikle daha iyi performans elde edilir.

Ancak, karmaşık modeller daha fazla eğitim verisi ve önemli ölçüde daha fazla hesaplama kaynağı (GPU/TPU) gerektirir.

Basit modeller daha hızlı eğitilir, daha az kaynağa ihtiyaç duyar ve daha kolay yorumlanır.



Etik ve Önyargı (Bias) Sorunları

MÖ modelleri, eğitildikleri verideki önyargıları (bias) yansıtır ve hatta büyütebilir.

Veri setindeki tarihsel veya sosyal eşitsizlikler, modelin azınlık gruplarına karşı ayrımcı kararlar vermesine neden olabilir.

Adil (Fair) MÖ sistemleri tasarlamak, günümüzün en önemli akademik ve endüstriyel zorluklarından biridir.



Model Yorumlanabilirliği (Explainability)

Bazı karmaşık MÖ modelleri (özellikle derin öğrenme), 'kara kutu' (black box) olarak adlandırılır, çünkü kararlarının nedenlerini açıklamak zordur. Model yorumlanabilirliği (Explainable AI - XAI), modelin tahminlerinin anlaşılmasına olanak tanır. Özellikle tıbbi teşhis ve finans gibi yüksek riskli alanlarda yorumlanabilirlik kritiktir.



Gelecek Perspektifleri: AutoML

AutoML (Automated Machine Learning), bir MÖ projesinin yaşam döngüsündeki adımların (veri ön işleme, özellik mühendisliği, model seçimi, hiperparametre ayarlaması) otomatikleştirilmesini amaçlar. AutoML, uzman olmayan kullanıcıların bile hızlı ve etkin modeller oluşturmalarını sağlar. Bu, MÖ alanını demokratikleştiren bir yaklaşımdır.

Gelecek Perspektifleri: Uç Bilişim (Edge Computing)

Uç bilişimde, MÖ modelleri merkezi sunucular yerine doğrudan cihazların (cep telefonları, kameralar, sensörler) üzerinde çalıştırılır.

Avantajları: Daha düşük gecikme süresi, artan gizlilik (veri cihazdan ayrılmaz) ve daha az bant genişliği ihtiyacı.

Örnekler: Akıllı telefonlarda yüz tanıma veya sesli komut işleme.

Gelecek Perspektifleri: Veri Ekonomisi

Makine öğrenmesinin temel girdisi olan veri, günümüz ekonomisinin en değerli kaynağıdır.

Veri mahremiyeti (privacy) ve güvenliği, MÖ projeleri için temel bir zorluktur. Federated Learning (Federe Öğrenme) gibi yeni teknikler, verinin yerinde kalarak modelin eğitilmesine olanak tanır, böylece mahremiyet korunur.



Vaka Çalışması: Denetimli Öğrenme (Sınıflandırma)

Problem: Müşterinin kredi geri ödeme olasılığını tahmin etmek (ikili Sınıflandırma: Öder/Ödemez).

Bağımsız Değişkenler: Yaş, gelir, kredi geçmişi, borç oranı.

Algoritma: Lojistik Regresyon veya Karar Ağaçları.

Metrik: Kesinlik (Precision), bankanın yanlış pozitifleri (ödemeyecek birine kredi vermek) en aza indirmesi kritik.



Vaka Çalışması: Denetimli Öğrenme (Regresyon)

Problem: Bir evin piyasa değerini tahmin etmek (Sürekli Değer Kestirimi).
Bağımsız Değişkenler: Metrekare, konum, oda sayısı, inşa yılı.
Algoritma: Doğrusal Regresyon veya Rastgele Ormanlar (Regresör).
Metrik: RMSE, tahmini hatanın ortalama dolar cinsinden ne kadar olduğunu gösterir.



Vaka Çalışması: Denetimsiz Öğrenme (Kümeleme)

Problem: Müşterileri benzer satın alma davranışlarına göre gruplamak (Etiketsiz).

Özellikler: Harcama sıklığı, son satın alma tarihi, toplam harcama miktarı.

Algoritma: K-Means Kümeleme.

Kullanım: Farklı segmentlere özel pazarlama stratejileri geliştirmek.

Veri Ön İşleme Teknikleri: Normalizasyon ve Standardizasyon

Normalizasyon: Veri değerlerini genellikle 0 ile 1 arasına ölçeklendirir.

Standardizasyon: Veri değerlerini ortalaması 0 ve standart sapması 1 olacak şekilde dönüştürür (Z-skoru).

Bu işlemler, özellikle mesafe tabanlı algoritmalarda (K-NN, SVM) büyük ölçekli özelliklerin küçük ölçekli özellikleri domine etmesini engeller.



Kategorik Veri İşleme: One-Hot Encoding

One-Hot Encoding, nominal (isimsel) kategorik değişkenleri makine öğrenmesi algoritmalarının anlayabileceği ikili (binary) formata dönüştürür. Her kategori için yeni bir sütun oluşturulur ve ilgili satırda sadece o kategoriye ait sütun 1, diğerleri 0 olarak işaretlenir. Bu, kategoriler arasında yanlış bir sıralama ilişkisi kurulmasını engeller.

Eksik Değerlerin Yönetimi

Eksik değerler, modelin doğruluğunu ciddi şekilde düşürebilir.

Yönetim stratejileri:

1. Silme: Eksik değere sahip satır veya sütunların kaldırılması.
 2. Doldurma (Imputation): Eksik değerlerin ortalama, medyan, mod veya daha karmaşık bir MÖ modeli ile tahmin edilerek yerine konması.
- Karar, eksik verinin miktarına ve türüne bağlıdır.

Makine Öğrenmesi İçin Veri Kalitesinin Önemi

Modelin başarısı doğrudan eğitim verisinin kalitesine bağlıdır. Kirli, gürültülü veya hatalı etiketlenmiş veriler (Garbage In), her ne kadar gelişmiş olursa olsun, kötü performans gösteren bir model (Garbage Out) ile sonuçlanır.

Bu nedenle, veri ön işleme aşaması projenin %60-80'ini oluşturabilir.



Denetimli Öğrenme Sınıflandırma: Çoklu Etiket (Multi-Label)

Çoklu Sınıflandırmadan farklı olarak, Çoklu Etiket sınıflandırmada bir veri noktası aynı anda birden fazla kategoriye ait olabilir.

Örnek: Bir filmin etiketlenmesi (Aksiyon, Komedi ve Bilim Kurgu).

Bu tür problemler, genellikle birden çok ikili sınıflandırıcının birleştirilmesiyle çözülür.



Birliktelik Kuralı Madenciliği (Association Rule Mining), veri setlerinde sıkça birlikte görülen öğeleri veya olayları bulmayı amaçlar.

En bilinen algoritması Apriori'dir.

Uygulama: Müşteri bir ürünü aldığında, büyük olasılıkla hangi diğer ürünü de alacağını tahmin etmek (Pazar Sepeti Analizi).



Denetimli Öğrenme Algoritmaları: K-En Yakın Komşu (K-NN)

K-NN, bir tahmin yapılması gerektiğinde, yeni veri noktasına en yakın K sayıda komşuyu bulur.

Sınıflandırmada: Komşuların en çok oy verdiği sınıfı atar.

Regresyonda: Komşuların değerlerinin ortalamasını alır.

Avantajı: Basit olması ve eğitim aşamasının çok hızlı olması.



Model Seçiminde Hata: Varyans ve Sapma (Bias-Variance Trade-off)

Bias (Sapma): Modelin gerçek ilişkiden ne kadar uzak olduğunu gösterir (Underfitting ile ilişkilidir).

Varyans (Variance): Modelin farklı veri setlerindeki küçük değişikliklere ne kadar hassas olduğunu gösterir (Overfitting ile ilişkilidir).

İyi bir model, düşük sapma ve düşük varyansı dengelemelidir.

Çapraz Doğrulama (Cross-Validation)

Çapraz doğrulama (özellikle K-Fold), veri setini K eşit parçaya böler. Model K defa eğitilir; her seferinde K-1 parça eğitim için, kalan 1 parça doğrulama/test için kullanılır.

Bu, modelin performansının tek bir test setine bağlı olmamasını sağlar ve sonuçların kararlılığını artırır.



Algoritma Seçimi: Önemli Kriterler

Veri Seti Boyutu: Büyük veri setleri için genellikle daha karmaşık algoritmalar (derin öğrenme) gerekir.

Eğitim Süresi: Bazı modeller (SVM, büyük sinir ağları) çok yavaş eğitilir.

Tahmin Hızı: Gerçek zamanlı sistemler için hızlı tahmin yapabilen modeller tercih edilir.

Yorumlanabilirlik İhtiyacı: Şeffaflık gereken durumlarda Karar Ağaçları veya Lojistik Regresyon seçilir.



Özet ve Temel Çıkarımlar

Makine öğrenmesi, kural tabanlı programlamanın aksine, veri ve sonuçlardan kuralları öğrenir.

Temel türler: Etiketli veri ile çalışan Denetimli (Sınıflandırma, Regresyon) ve etiketsiz veri ile çalışan Denetimsiz (Kümeleme).

Projenin başarısı, doğru veri hazırlama, uygun model seçimi ve doğru değerlendirme metriklerine bağlıdır.

Sonuç: Makine Öğrenmesinin Geleceği

Makine öğrenmesi, yapay zekanın motoru olarak kalmaya devam edecektir. Alan, daha az veriye ihtiyaç duyan, daha adil ve daha yorumlanabilir modeller geliştirmeye odaklanmaktadır. Üniversite öğrencileri için bu alanın temelini anlamak, geleceğin teknolojilerine yön vermek açısından hayati öneme sahiptir.



Veri Madenciliği ve Makine Öğrenmesi Algoritmaları

Süleyman **EZDEMİR**

suleyman.ezdemir@giresun.edu.tr

