

K-En Yakın Komşu (K-NN) Sınıflandırmasına Giriş

Veri Mad. – Hafta 9



K-En Yakın Komşu (K-NN) Sınıflandırmasına Giriş

Bu hafta, parametrik olmayan (non-parametric) makine öğrenimi algoritmalarının temelini oluşturan K-En Yakın Komşu (K-NN) algoritmasını inceleyeceğiz.

K-NN, tıbbi teşhis (özellikle meme kanseri) gibi kritik alanlarda basit ama etkili bir sınıflandırma aracı olarak kullanılır.

K-NN, bir 'tembel öğrenme' (lazy learning) algoritmasıdır, yani eğitim verisini doğrudan ezberler ve tahmin anına kadar hesaplama yapmaz.



K-NN: Tembel Öğrenmenin Tanımı ve Felsefesi

Geleneksel (eager) öğrenme algoritmaları (örn. Karar Ağaçları), eğitim aşamasında bir model oluşturur veya parametreleri optimize eder. K-NN ise, eğitim aşamasında karmaşık bir model 'öğrenmez'. Bunun yerine, tüm eğitim verisi setini bellekte saklar (ezberler). Model, tüm hesaplamayı, yeni bir veri noktası geldiğinde (tahmin aşaması) gerçekleştirir. Bu yaklaşım, model güncellemesini kolaylaştırırken, tahmin süresini veri seti boyutuna bağlı olarak uzatabilir.



Parametrik Olmayan Algoritmalar (Non-Parametric)

Parametrik algoritmalar (örn. Doğrusal Regresyon), verinin belirli bir dağılıma (genellikle normal dağılım) sahip olduğunu varsayar ve bu dağılımı tanımlayan sabit sayıda parametreyi öğrenir.

Parametrik olmayan algoritmalar ise, verinin altında yatan dağılım hakkında hiçbir ön varsayımda bulunmaz.

Model karmaşıklığı, veri boyutuyla birlikte artar.

Bu durum, K-NN'in verinin yerel yapısına (local structure) daha iyi uyum sağlamasına olanak tanır.



K-NN Temel Teorisi: Sezgisel Fikir

K-NN'in temel prensibi son derece sezgisellik üzerine kurulmuştur: 'Bana arkadaşlarını (komşularını) söyle, sana kim olduğunu söyleyeyim'.
Veri biliminde bu, benzer özelliklere sahip veri noktalarının büyük olasılıkla aynı sınıfa ait olacağı anlamına gelir.
Yeni bir veri noktasının (sorgu noktası) sınıfı, o noktaya en yakın 'K' adet eğitim verisi noktasına bakılarak belirlenir.



Sınıflandırma Mekanizması: Çoğunluk Oylaması

Bir sorgu noktasının sınıfını belirlemek için, bulunan 'K' komşu arasındaki sınıfların çoğunluk oylaması (majority vote) yapılır. Örneğin, $K=5$ ise ve 3 komşu A sınıfına, 2 komşu B sınıfına aitse, yeni nokta A sınıfına atanır. Bu süreç, K-NN'in temel sınıflandırma adımıdır.

Uzaklık Metriklerinin Rolü: 'En Yakın' Tanımı

K-NN algoritmasında 'en yakın' komşuyu tanımlayan şey, kullanılan Uzaklık Metriği'dir.

Farklı metrikler kullanmak, aynı veri seti üzerinde farklı komşuların seçilmesine ve dolayısıyla farklı tahmin sonuçlarına yol açabilir.

Uzaklık metrikleri, özellik uzayında iki nokta arasındaki benzerliği veya ayrılığı nicelleştirir.



Öklid Mesafesi (Euclidean Distance)

Öklid Mesafesi, iki nokta arasındaki düz çizgi üzerindeki en kısa mesafeyi hesaplar.

En yaygın kullanılan uzaklık metriğidir ve genellikle varsayılan metrik olarak kabul edilir.

İki nokta arasındaki farkların karelerinin toplamının karekökü alınarak hesaplanır.

Öklid mesafesi, özelliklerin ölçeklerine karşı hassastır, bu da ölçeklendirmenin zorunlu olmasının ana nedenidir.



Manhattan Mesafesi (City Block Distance)

Manhattan Mesafesi, iki nokta arasındaki dikey ve yatay eksenler boyunca izlenen mesafeyi hesaplar, tıpkı bir şehrin blokları arasında gitmek gibi (Taksi Mesafesi).

Bu mesafe, özellikler arasındaki mutlak farkların toplamıdır.

Özellikle özellik uzayının döndürülmesinin veya aykırı değerlerin etkisinin azaltılmasının istendiği durumlarda tercih edilebilir.



Minkowski Mesafesi: Metriklerin Genelleştirilmesi

Minkowski Mesafesi, Öklid ve Manhattan mesafelerinin genelleştirilmiş bir halidir.

p parametresi kullanılarak tanımlanır:

$p=1$ olduğunda, Minkowski Mesafesi Manhattan Mesafesine dönüşür.

$p=2$ olduğunda, Minkowski Mesafesi Öklid Mesafesine dönüşür.

Farklı p değerleri seçilerek uzaydaki mesafe algısı değiştirilebilir.

Optimal 'K' Değeri: K-NN'in En Önemli Hiperparametresi

K-NN algoritmasının tek ve en kritik hiperparametresi 'K' değeridir. K'nın seçimi, modelin karmaşıklığını ve genelleme yeteneğini doğrudan belirler.

Yanlış K değeri seçimi, modelin ya aşırı öğrenmesine (overfitting) ya da az öğrenmesine (underfitting) neden olabilir.

Bu parametre, eğitim verisi üzerinden değil, çapraz doğrulama (cross-validation) yöntemleriyle optimize edilmelidir.

Düşük 'K' Değerinin Etkileri (Örnek: $K=1$)

Çok düşük bir K değeri seçildiğinde (örneğin $K=1$), model sadece en yakın tek noktaya odaklanır.

Bu durum, modelin veri setindeki yerel gürültüye (noise) ve aykırı değerlere (outliers) karşı aşırı hassas olmasına yol açar.

Sonuç: Model, eğitim verisine mükemmel uyar (düşük sapma), ancak yeni, görülmemiş verilere genelleme yapma yeteneği düşer (yüksek varyans). Bu duruma aşırı öğrenme (overfitting) denir.

Yüksek 'K' Değerinin Etkileri (Örnek: $K=N$)

Çok yüksek bir K değeri (tüm veri setinin boyutu N'ye yakın), modelin çok geniş bir alana bakmasına neden olur.

Model, veri setindeki en baskın (dominant) sınıfa doğru saplanır (high bias).

Bu, verinin ince yerel yapısını ve sınırlarını gözden kaçırmasına neden olur.

Sonuç: Model, hem eğitim hem de test verilerinde kötü performans gösterir (yüksek sapma). Bu duruma az öğrenme (underfitting) denir.

Optimal K Seçimi ve Eşitlik Durumu

Optimal 'K' değeri, modelin sapma (bias) ve varyans (variance) arasındaki en iyi dengeyi kurduğu noktadır.

Bu değer, genellikle modelin hata oranının düşmeyi bıraktığı noktada bulunur. Oylamada eşitlik (tie) durumunu engellemek için, genellikle 'K' değerinin tek sayı (odd number) olması şiddetle tavsiye edilir.

Eşitlik durumunda, bazı implementasyonlar rastgele seçim yapabilir veya mesafeye göre ağırlıklandırılmış oylama kullanabilir.



K-NN'in En Büyük Zafiyeti: Boyutluluk Laneti

K-NN'in en büyük teknik zafiyeti, Boyutluluk Laneti (Curse of Dimensionality) olarak bilinir.

Boyutluluk, veri setindeki özellik sayısını (feature count) ifade eder.

Özellik sayısı çok yüksek boyutlara ulaştığında, veri uzayı aşırı derecede seyrelir (sparse).

Boyutluluk Lanetinin K-NN Üzerindeki Etkisi

Boyutluluk arttıkça, özellik uzayındaki noktalar arasındaki göreceli mesafeler anlamlılığını yitirmeye başlar.

Çok yüksek boyutlarda, tüm noktalar birbirinden 'eşit derecede uzak' görünmeye başlar.

Bu, komşuluk kavramını işlevsiz hale getirir, çünkü her nokta birbirine 'yakın' veya 'uzak' olarak net bir şekilde ayrılamaz.

Bu nedenle K-NN, çok yüksek boyutlu verilerde genellikle zayıf performans gösterir.



K-NN'in Uygulama Alanları ve Sınırlamaları

K-NN, basitliği ve yorumlanabilirliği nedeniyle ilk sınıflandırma denemelerinde sıkça kullanılır.

Özellikle özellik sayısı düşük ve örnek sayısı çok büyük olmayan veri setlerinde etkilidir.

Sınırlamalar:

1. Boyutluluk Laneti: Yüksek boyutlarda performans düşer.
2. Hesaplama Maliyeti: Her tahmin, tüm eğitim setine olan uzaklık hesaplamasını gerektirir (yavaş tahmin süresi).
3. Bellek İhtiyacı: Tüm eğitim setinin bellekte tutulması gerekir.



Vaka Çalışması: Breast Cancer Wisconsin (Diagnostic) Veri Seti

Bu hafta kullanılan veri seti, Meme Kanseri Wisconsin (Diagnostic) (BCWD) veri setidir.

Veri seti, meme kanseri tümörlerinin dijital görüntülerinden elde edilen özellikleri içerir.

Temel amaç: Tümörün 'iyi huylu' (Benign) veya 'kötü huylu' (Malignant) olup olmadığını sınıflandırmaktır.

Bu, makine öğreniminde kritik öneme sahip, yaygın olarak kullanılan bir ikili sınıflandırma (binary classification) problemidir.

BCWD Veri Setinin Yapısı ve Özellikleri

BCWD veri seti, toplam 569 örneklem (tümör örneği) içerir. Her örneklem için 30 farklı sayısal özellik bulunmaktadır. Bu özellikler, hücre çekirdeğinin dijital görüntü analizinden türetilmiştir. Özellikler arasında yarıçap (radius), doku (texture), çevre (perimeter), alan (area) ve pürüzsüzlük (smoothness) gibi ölçümler yer alır.

Özellik Ölçeklendirme (Feature Scaling) Zorunluluğu

Bu veri setinin pedagojik önemi, özellik ölçeklendirme ihtiyacını somutlaştırmasıdır.

Veri setinde, 'alan' (area) gibi binlerle ifade edilen özellikler ile 'pürüzsüzlük' (smoothness) gibi 0.01-0.1 aralığındaki özellikler yan yanadır.

Bu büyük ölçek farklılıkları, K-NN ve diğer uzaklık tabanlı algoritmalar için ciddi sorunlar yaratır.



Uzaklık Hesaplamasında Ölçeğin Hakimiyeti

K-NN uzaklık tabanlı (distance-based) bir algoritmadır. Eğer ölçeklendirme yapılmazsa, uzaklık hesabı tamamen 'alan' (area) gibi büyük sayısal değerlere sahip özellikler tarafından domine edilir. 'Pürüzsüzlük' (smoothness) gibi küçük değerli özelliklerin uzaklık hesaplamasına katkısı ihmal edilebilir hale gelir, bu da modelin önemli bilgileri kaçırmalarına neden olur. Bu durum, modelin performansını ciddi şekilde düşürür ve hatalı komşu seçimine yol açar.



Uzaklık Tabanlı Algoritmalar ve Scaling

K-NN, Destek Vektör Makineleri (SVM) ve K-Ortalama (K-Means) gibi algoritmalar, karar verme süreçlerini doğrudan özellikler arasındaki mesafelere dayandırdığı için ölçeklendirme zorunludur.

Ölçeklendirme, tüm özelliklerin eşit ağırlığa sahip olmasını ve modelin her bir özelliğin katkısını adil bir şekilde değerlendirmesini sağlar.

Ölçeklendirme yöntemleri genellikle Standardizasyon veya Normalizasyondur.

StandardScaler: Standardizasyon Yöntemi

StandardScaler, en yaygın kullanılan ölçeklendirme yöntemlerinden biridir. Özellikleri, ortalamaları (μ) sıfır ve standart sapmaları (σ) bir olacak şekilde dönüştürür (Z-skoru normalizasyonu).

Formül: $Z = (x - \mu) / \sigma$.

Bu yöntem, aykırı değerlerin (outliers) etkisini tamamen kaldırmaz, ancak veriyi standart bir dağılıma yaklaştırır.

MinMaxScaler: Normalizasyon Yöntemi

MinMaxScaler, veriyi belirli bir minimum ve maksimum değer aralığına (genellikle 0 ile 1 arasına) ölçeklendirir.

Formül: $(x - \min(x)) / (\max(x) - \min(x))$.

Özellikle yapay sinir ağları (neural networks) gibi, giriş değerlerinin küçük ve belirli bir aralıkta olmasını bekleyen algoritmalarda faydalıdır.

Python Uygulaması: Verinin Yüklenmesi ve Ayırılması

Uygulama, Google Colab ortamında Python ve Scikit-learn kütüphaneleri kullanılarak gerçekleştirilir.

Adım 1: Verinin Yüklenmesi.

`sklearn.datasets.load_breast_cancer()` fonksiyonu kullanılarak BCWD veri seti kolayca yüklenir.

Adım 2: Verinin Eğitime ve Teste Ayırılması.

`train_test_split` fonksiyonu 31 ile veri, eğitim (training) ve test (testing) setleri olarak bölünür. Bu, modelin genelleme yeteneğini ölçmek için kritiktir.

Kritik Ön İşleme Adımı: Ölçekleyicinin Eğitimi

Ölçeklendirme sürecinde en kritik adım, veri sızıntısını (data leakage) engellemektir.

`scaler.fit(X_train)`: StandardScaler nesnesi, SADECE eğitim verisinin (`X_train`) ortalamasını (μ) ve standart sapmasını (σ) öğrenir.

Test verisinin istatistiksel bilgisi (ortalama ve sapma) modelin eğitimine veya ön işleme adımlarına ASLA sızdırılmamalıdır.

Ölçekleyici Uygulaması (Transformasyon)

Eğitim verisi (X_{train}) ve Test verisi (X_{test}) ayrı ayrı dönüştürülür. Her iki dönüşümde de, SADECE eğitim setinden öğrenilen μ ve σ değerleri kullanılır.

$X_{\text{train_scaled}} = \text{scaler.transform}(X_{\text{train}})$

$X_{\text{test_scaled}} = \text{scaler.transform}(X_{\text{test}})$

Bu dönüşüm sonucunda, özellikler ölçeklendirilmiş ve K-NN için uygun hale getirilmiş olur.

Optimal 'K' Değerini Bulma: Dirsek Yöntemi (Elbow Method)

K'nın en iyi değerini bulmak için yaygın kullanılan yöntemlerden biri Dirsek Yöntemi (Elbow Method)'dir.
Bu yöntem, belirli bir K aralığında (örn. 1'den 30'a kadar) K-NN modelleri eğitilerek test edilir.
Her K değeri için test seti üzerindeki hata oranı (veya $1 - \text{Accuracy}$) kaydedilir.

Dirsek Grafiğinin Yorumlanması

K değerlerine (X eksen) karşılık hata oranlarının (Y eksen) çizildiği çizgi grafiği analiz edilir.

Grafikte hatanın hızla düşmeyi bıraktığı ve yataylaşmaya başladığı nokta 'dirsek' (elbow) olarak adlandırılır.

Bu 'dirsek' noktası, modelin yüksek sapma ve yüksek varyans arasında en iyi dengeyi (optimal K) bulduğu K değerini gösterir.



Modelin Eğitimi ve Tahmin Aşaması

Optimal 'K' değeri belirlendikten sonra, Scikit-learn'den KNeighborsClassifier modeli kurulur.

Model, ölçeklendirilmiş eğitim verisi (`X_train_scaled`) ve etiketleri (`y_train`) kullanılarak eğitilir.

`fit(X_train_scaled, y_train)` komutu ile eğitim gerçekleştirilir. (Bu aşama, tembel öğrenme olduğu için aslında sadece veriyi kaydetmeyi içerir.)

Eğitilen model daha sonra ölçeklendirilmiş test verisi (`X_test_scaled`) üzerinde tahminler yapmak için kullanılır.

Model Çıktılarının Görselleştirilmesi: Hata Matrisi

Hata Matrisi (Confusion Matrix), sınıflandırma modelinin ne tür hatalar yaptığını ve hangi sınıfları doğru tahmin ettiğini görselleştiren standart bir araçtır.

Bu matris, modelin performansını tek bir doğruluk (accuracy) metriğinden daha detaylı anlamamızı sağlar.

Hata matrisi, gerçek sınıflar (satırlar) ile tahmin edilen sınıflar (sütunlar) arasındaki ilişkiyi gösterir.



Hata Matrisi Bileşenleri: Doğru Pozitif (TP) ve Doğru Negatif (TN)

True Positive (TP): Gerçekte pozitif olan durumun (Malignant) pozitif olarak tahmin edilmesi (Kötü Huylu başarılı teşhis).

True Negative (TN): Gerçekte negatif olan durumun (Benign) negatif olarak tahmin edilmesi (İyi Huylu başarılı teşhis).

Tıbbi teşhis senaryosunda, bu iki değer modelin doğru kararlarını temsil eder.



Hata Matrisi Bileşenleri: Yanlış Pozitif (FP)

False Positive (FP): Gerçekte negatif olan bir durumun (Benign, İyi Huylu) pozitif olarak tahmin edilmesi (Kötü Huylu teşhisi). Bu, Tip I Hata olarak da bilinir. Breast Cancer senaryosunda: Gerçekte İyi Huylu olan bir tümöre 'Kötü Huylu' demek.

Maliyeti: Gereksiz panik, ek ve masraflı testler, potansiyel olarak gereksiz biyopsi veya tedavi başlangıcı. Bu, FN kadar hayati tehlike oluşturmaz.



Hata Matrisi Bileşenleri: Yanlış Negatif (FN)

False Negative (FN): Gerçekte pozitif olan bir durumun (Malignant, Kötü Huylu) negatif olarak tahmin edilmesi (iyi Huylu teşhisi). Bu, Tip II Hata olarak da bilinir.

Breast Cancer senaryosunda: Gerçekte Kötü Huylu olan bir tümöre 'İyi Huylu' demek.

Maliyeti: Bu, tıbbi teşhis senaryosunda en tehlikeli ve maliyeti en yüksek hatadır. Yanlış negatif, kritik bir hastalığın teşhisini geciktirir, tedavi şansını azaltır.



Tıbbi Teşhiste Kritik Metrikler: Recall (Duyarlılık)

Tıbbi teşhis gibi hayati senaryolarda, Recall (Duyarlılık) metriği kritik öneme sahiptir.

Recall, gerçekte pozitif olan tüm vakaların ne kadarının model tarafından doğru bir şekilde pozitif olarak tanımlandığını ölçer. ($\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$). FN'yi (kötü huylu vakayı kaçırma) minimize etmeyi hedefler. Yüksek bir Recall, modelin kötü huylu vakaları kaçırmada düşük bir orana sahip olduğunu gösterir.



Precision (Kesinlik) Metriği

Precision (Kesinlik), modelin pozitif olarak tahmin ettiği durumların ne kadarının gerçekten pozitif olduğunu ölçer. ($\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$).

Yüksek bir kesinlik, doktorların modelin 'kötü huylu' dediği sonuca güvenebileceği anlamına gelir (gereksiz biyopsi riskini azaltır).

Ancak, genellikle tıbbi taramalarda önce Recall maksimize edilmeye çalışılır, çünkü bir hayatı kaçırmamanın maliyeti, gereksiz bir test yapmanın maliyetinden çok daha yüksektir.



F1 Skoru ve Genel Doğruluk (Accuracy)

Genel Doğruluk (Accuracy), doğru tahminlerin toplam tahminlere oranını verir. İkili sınıflandırmada ilk bakılan metrik olsa da, dengesiz veri setlerinde yanıltıcı olabilir.

F1 Skoru, Precision ve Recall'un harmonik ortalamasıdır. Hem FP hem de FN'yi dikkate aldığı için dengeli bir model performansı ölçümü sağlar. Performans değerlendirmesinde (confusion_matrix ve classification_report kullanılarak) tüm bu metrikler göz önünde bulundurulmalıdır.



Classification Report'un Yorumlanması

Scikit-learn'deki `classification_report`, Precision, Recall ve F1 Skorunu her sınıf (Benign ve Malignant) için ayrı ayrı sunar.

Yorumlama sırasında, özellikle 'Malignant' (kötü huylu) sınıfı için elde edilen Recall değerine odaklanılmalıdır.

Bu değer yüksek olması, modelin klinik açıdan başarılı olduğunu gösterir.



Ölçeklendirmenin Kritik Etkisinin Kanıtı

Öğrencilerden, K-NN modelini bir de özellik ölçeklendirmesi (scaling) yapmadan eğitmeleri ve performansını raporlamaları beklenir. Bu, ölçeklendirilmiş veri ile elde edilen yüksek performanslı raporla karşılaştırılarak, özellik ölçeklendirmenin K-NN üzerindeki kritik etkisi somut bir şekilde kanıtlanır. Beklenen sonuç: Ölçeklendirilmemiş veri ile eğitilen modelin doğruluğu ve özellikle 'Malignant' sınıfı Recall değeri belirgin şekilde düşük olacaktır.



Ek Konu: K-NN Optimizasyonu ve Ağırlıklandırma

Standart K-NN, tüm K komşusuna eşit ağırlık verir (basit çoğunluk oylaması). Ağırlıklandırılmış K-NN'de, komşunun sınıfa katkısı mesafesiyle ters orantılıdır. Yani, sorgu noktasına daha yakın olan komşular, daha uzaktaki komşulardan daha fazla ağırlığa sahip olur. Bu, aykırı değerlerin (outliers) etkisini azaltmaya yardımcı olabilir ve modelin yerel yapıyı daha iyi yakalamasını sağlar.

Ek Konu: Optimal K Seçimi İçin Alternatif Yöntemler

Dirsek yöntemine ek olarak, K değerini sistematik olarak seçmek için Grid Search (Izgara Arama) ve Çapraz Doğrulama (Cross-Validation) teknikleri kullanılır.

Grid Search, hiperparametre uzayındaki tüm olası K değer kombinasyonlarını dener.

K-Fold Cross-Validation, veri setini katlara bölerek modelin genelleme performansını daha güvenilir bir şekilde tahmin eder, böylece en iyi K değeri seçilir.



Ek Konu: K-NN ve Büyük Veri Setleri

K-NN'in temel dezavantajı olan yavaş tahmin süresini iyileştirmek için, tüm veri noktalarını taramak yerine komşuları daha hızlı bulmak gerekir.

Bu amaçla, veriler genellikle K-D Ağaçları (K-D Trees) veya Top Ağaçları (Ball Trees) gibi uzamsal indeksleme yapıları kullanılarak organize edilir.

Bu yapılar, özellikle düşük boyutlu verilerde, tahmin süresini $O(N)$ 'den $O(\log N)$ 'e kadar düşürebilir.

Tıbbi Görüntü İşlemede K-NN'in Yeri

K-NN, meme kanseri teşhisindeki gibi tıbbi görüntü verilerinde, özellik çıkarımı (feature extraction) yapıldıktan sonra sınıflandırma katmanı olarak kullanılabilir.

Özellikler (yarıçap, doku vb.) doğrudan hücre çekirdeği görüntülerinden çıkarılır.

K-NN'in basitliği ve yerel kararlara dayanması, sonuçların klinik olarak yorumlanmasını kolaylaştırır.

K-NN Uygulama Adımlarının Özeti (1/2)

1. Veriyi Yükle: `sklearn.datasets.load_breast_cancer()`.
2. Veriyi Ayır: `train_test_split` ile eğitim ve test setlerine ayır.
3. Ölçekleyiciyi Seç: `StandardScaler` nesnesini oluştur.
4. Ölçekleyiciyi Eğit: Sadece `X_train` üzerinde fit et (μ ve σ öğrenilir).
5. Veriyi Dönüştür: Hem `X_train` hem de `X_test`'i öğrenilen parametrelerle transform et.

K-NN Uygulama Adımlarının Özeti (2/2)

6. Optimal K'yı Bul: Hata oranına karşı K çizimi yaparak (Elbow Method) en iyi K'yı belirle.
7. Modeli Kur ve Eğit: Optimal K ile KNeighborsClassifier oluştur ve ölçeklendirilmiş eğitim verisiyle fit et.
8. Tahmin Yap: Ölçeklendirilmiş test verisi üzerinde tahminleri al.
9. Performansı Değerlendir: Confusion Matrix (Hata Matrisi) ve Classification Report oluştur.
10. Kritik Metriği Yorumla: Özellikle 'Malignant' sınıfı için Recall değerine odaklanarak modelin klinik başarısını değerlendir.

K-NN Uygulamasında Dikkat Edilmesi Gerekenler

Dengesiz Sınıflar (Imbalanced Classes): Eğer Malignant örnekler Benign örneklerle göre çok az ise, basit çoğunluk oylaması yetersiz kalabilir. Bu durumda ağırlıklandırma veya veri dengeleme teknikleri gerekir.

Etiketleme Maliyetleri: K-NN'in 'ezberleme' doğası nedeniyle, etiketleme hatalarına karşı hassastır.

Özellik Seçimi: Yüksek boyutluluktan kaçınmak için, alakasız veya gürültülü özelliklerin önceden elenmesi (Feature Selection) önemlidir.

Karar Sınırları (Decision Boundaries) ve K

K-NN, parametrik olmadığı için karmaşık ve düzensiz karar sınırları oluşturabilir.

Düşük K değeri (örn. $K=1$) kullanıldığında, karar sınırları çok dalgalı ve düzensiz (yüksek varyans) hale gelir.

Yüksek K değeri kullanıldığında, karar sınırları daha yumuşak, genel hatlara sahip (yüksek sapma) hale gelir.

Optimal K, karar sınırlarının hem genelleştirilebilir hem de yerel yapıyı yansıtabilir olmasını sağlar.



Mesafe Ağırlıklandırmanın Teknik Detayı

Ağırlıklandırılmış K-NN'de bir komşunun oyu, sorgu noktasına olan mesafesinin tersiyle orantılıdır.

Örneğin, $w_i = 1 / d(x, x_i)$, burada d mesafedir.

Çoğunluk oylaması yerine, ağırlıklandırılmış oylama kullanılır.

Bu, en yakın komşuların kararı domine etmesini sağlarken, daha uzaktaki komşuların etkisini korur.



K-NN'in Regresyon Amaçlı Kullanımı

K-NN sadece sınıflandırma için değil, regresyon problemleri (sürekli bir değer tahmin etme) için de kullanılabilir.

K-NN regresyonda, tahmin, 'K' en yakın komşunun etiket değerlerinin (gerçek çıktı değerlerinin) ortalaması alınarak yapılır.

Örneğin, ev fiyatı tahmini yapılıyorsa, en yakın K evin fiyatlarının ortalaması tahmin olarak kullanılır.



Tıbbi ML: Erken Teşhisin Önemi

Meme kanseri tanısında zamanlama hayati önem taşır.
İyi huylu (Benign) tümörler kanser değildir ve genellikle cerrahi müdahale gerektirmez.
Kötü huylu (Malignant) tümörler ise hızlı yayılma potansiyeline sahiptir.
K-NN gibi ML modellerinin amacı, doktorlara destek olarak, Malignant vakaları olabildiğince erken ve güvenilir bir şekilde tespit etmektir.

BCWD verisindeki 30 özellik, genellikle hücre çekirdeğinin üç farklı istatistiğini temsil eder:

1. Ortalama (Mean) değerler.
2. Standart Hata (Standard Error) değerleri (değişkenliği gösterir).
3. 'En Kötü' (Worst) değerler (hücrenin en uç veya en büyük değerlerini temsil eder).

Bu özelliklerin hepsi, modelin nihai kararına katkıda bulunur ve ölçeklendirme gerektirir.

K-NN: Hesaplama Maliyetinin Derinlemesine Analizi

Eğitim Aşaması: K-NN'in eğitimi çok hızlıdır, çünkü sadece veriyi bellekte depolar. $O(1)$ veya $O(N)$ (veri kopyalama).

Tahmin Aşaması: Yeni bir nokta geldiğinde, K-NN tüm eğitim setine olan uzaklıkları hesaplamalıdır. Eğer N örnek ve D özellik varsa, karmaşıklık $O(N \cdot D)$ olur.

Büyük N değerleri için tahmin süresi pratik olmayan derecede uzayabilir. Bu 'tembel' öğrenmenin temel maliyetidir.



BCWD: Veri Dağılımının Görselleştirilmesi

Gerçek bir veri analizi sırasında, model eğitiminden önce özelliklerin sınıflara göre nasıl dağıldığını görselleştirmek önemlidir.

Örneğin, 'radius_mean' ve 'texture_mean' gibi iki ana özellik seçilerek Benign ve Malignant sınıflarının dağılımı bir saçılım grafiği (scatter plot) üzerinde gösterilir.

Bu, K-NN'in komşuluk ilkesinin bu veride ne kadar etkili olacağını sezgisel olarak anlamamızı sağlar.



Ölçeklendirme Sonrası Veri Dağılımı

Ölçeklendirme, veri noktalarının özellik uzayındaki göreceli konumlarını değiştirmez (yani bir noktanın diğerine olan sırası değişmez). Ancak, koordinat sisteminin ölçeğini değiştirerek tüm özelliklerin 0 civarında merkezlenmesini ve standart bir yayılıma sahip olmasını sağlar. Bu, uzaklık hesaplamalarının artık tüm özellikler tarafından eşit şekilde etkilendiği anlamına gelir.

Model Seçimi ve Karşılaştırmalı Performans

K-NN, lojistik regresyon, destek vektör makineleri (SVM) ve karar ağaçları gibi diğer sınıflandırma algoritmalarıyla karşılaştırılmalıdır.

BCWD gibi düşük boyutlu ve iyi ayrılmış verilerde, K-NN genellikle yüksek doğruluk ve Recall elde edebilir.

Model seçimi, sadece performansa değil, aynı zamanda hız, bellek kullanımı ve yorumlanabilirlik gibi faktörlere de bağlıdır.



K-NN'in Güvenilirlik Aralıkları

Tıbbi teşhis senaryolarında, sadece sınıf tahmini (Malignant/Benign) değil, aynı zamanda bu tahminin ne kadar güvenilir olduğu da önemlidir. K-NN, çoğunluk oylaması oranları kullanılarak bir tahminin olasılığını veya güvenini çıkarabilir (örneğin, 5 komşudan 4'ü Malignant ise, güven %80'dir). Bu güven seviyesi, doktorlara nihai kararlarında ek bilgi sağlar.



Hiperparametre Ayarlama (Tuning) Detayları

Pratikte, sadece K değeri değil, aynı zamanda kullanılan uzaklık metriği (Euclidean, Manhattan, vb.) ve ağırlıklandırma türü (uniform, distance) de optimize edilmelidir.

Bu, genellikle Grid Search veya Random Search gibi sistematik yöntemler kullanılarak yapılır.

Örneğin, Grid Search ile K, metrik ve ağırlıklandırma parametrelerinin tüm kombinasyonları denenir ve en iyi metrik performansı veren kombinasyon seçilir.



BCWD Verisi: Dengeli Sınıf Dağılımı

BCWD veri seti (569 örneklem) genel olarak nispeten dengeli bir sınıf dağılımına sahiptir (yaklaşık 357 Benign, 212 Malignant).

Bu denge, basit doğruluk (Accuracy) metriğinin ilk değerlendirme için makul bir gösterge olmasını sağlar.

Ancak, tıbbi bağlam nedeniyle, yine de Malignant sınıfının Recall metriğine özel önem verilmelidir.



K-NN ve Gizlilik Koruması (Privacy)

K-NN, tüm eğitim verisini doğrudan sakladığı için, tahmin yaparken komşuların kim olduğunu göstererek veri gizliliği sorunlarına yol açabilir.

Özellikle tıbbi kayıtlarda, bir hastanın teşhisinin komşuları üzerinden dolaylı yoldan ortaya çıkma riski vardır.

Bu, K-NN'in dağıtık veya hassas veri setlerinde kullanılması durumunda Homomorfik Şifreleme (Homomorphic Encryption) gibi gizlilik koruma tekniklerinin gerekliliğini ortaya koyar.



SONUÇ: K-NN'in Klinik Uygulamalardaki Değeri

K-NN, parametrik olmayan yapısı sayesinde veri hakkında güçlü varsayımlar yapmadan sınıflandırma yapabilen güçlü bir araçtır.

Ancak, uzaklık tabanlı olması nedeniyle özellik ölçeklendirme (StandardScaler kullanımı) hayati öneme sahiptir.

Tıbbi teşhis senaryolarında, model performansını değerlendirirken Yanlış Negatifleri (FN) minimize etme hedefiyle Recall metriğine odaklanmak esastır. K-NN, basitliği ve güçlü yerel sezgiselliği nedeniyle ML uygulamalarına başlamak için mükemmel bir algoritmadır.

K-En Yakın Komşu (K-NN) Sınıflandırmasına Giriş

Süleyman **EZDEMİR**

suleyman.ezdemir@giresun.edu.tr

