

Rastgele Ormanlar (Random Forest)

Veri Mad. – Hafta 12

Rastgele Ormanlar (Random Forest) ve Şarap Kalitesi Analizi

Bu hafta, Topluluk Öğrenmesi (Ensemble Learning) felsefesini inceleyeceğiz. En güçlü ve yaygın kullanılan topluluk algoritması olan Rastgele Ormanlar'ın (Random Forest) teorik temellerini öğreneceğiz. Aşırı öğrenme (overfitting) sorununu nasıl çözdüğünü analiz edeceğiz. Şarap Kalitesi Veri Seti (Wine Quality Dataset) üzerinde bir uygulama gerçekleştireceğiz.



Karar Ağaçları'nın Tekrarı: Güçlü Ama Zayıf Yönler

Hafta 4'te Karar Ağaçları'nın (Decision Trees) güçlü ve kolay yorumlanabilir olduğunu gördük.

Ancak, tek başına bir Karar Ağacı'nın en büyük zafiyeti aşırı öğrenmeye (overfitting) yatkın olmasıdır.

Veri setindeki gürültüyü veya aykırı değerleri ezberleyebilirler ve genelleme yetenekleri düşüktür.



Çözüm: Topluluk Öğrenmesi (Ensemble Learning)

Rastgele Ormanlar, Topluluk Öğrenmesi felsefesini kullanır.

Temel fikir: Birçok zayıf öğrencinin bir araya gelerek tek, güçlü ve stabil bir öğrenci oluşturmasıdır.

Bu yöntem, tek bir modelin dezavantajlarını, birden fazla modelin kolektif bilgeliği ile dengelemeyi amaçlar.



Rastgele Orman Mimarisi

Rastgele Ormanlar, temelde birçok farklı Karar Ağacı yetiştirip, nihai kararı onlara oylatmaya dayanır.
Her bir ağaç, aynı problemi farklı bir bakış açısıyla çözer.
Bu 'çeşitlilik' (diversity), modelin stabilitesini ve genelleme yeteneğini artırır.



Rastgelelik Kaynakları

Bir Rastgele Orman'daki ağaçların birbirinden farklı (de-correlated) olması kritiktir.

Bu farklılığı sağlamak için iki temel rastgelelik tekniği kullanılır:

1. Örneklem Rastgeleliği (Bagging / Bootstrap Aggregating)
2. Özellik Rastgeleliği (Feature Randomness)



Bagging (Bootstrap Aggregating) Kavramı

Bagging, Rastgele Orman'ın ilk temel yapı taşıdır.
Amacı, her bir ağaç için farklı bir eğitim veri seti oluşturmaktır.

Bootstrap Mekanizması Detaylı İncelenmesi

Bootstrap, orijinal N adetlik eğitim verisinden, yerine koyarak (with replacement) rastgele N adetlik alt-örneklem (bootstrap samples) oluşturulmasıdır.

'Yerine koyarak' (with replacement) ne anlama gelir?

Bir veri noktasının birden fazla kez seçilebileceği anlamına gelir.



Bootstrap: Örneklem Büyüklüğü ve Bağımsızlık

Her bir bootstrap örneklem, orijinal veri setiyle aynı N büyüklüğündedir. Örneklem alındıktan sonra, her bir alt-örneklem üzerinde tamamen bağımsız bir Karar Ağacı eğitilir. Bu, Karar Ağaçlarının birbirini etkilememesini sağlar.

İstatistiksel Çıkarım: %63 Kuralı

İstatistiksel olarak, rastgele ve yerine koyarak örnekleme yapıldığında, her bir bootstrap örneklem, orijinal verinin yaklaşık %63'ünü içerir. Bu, ağaçların, veri setinin yalnızca bir kısmını görüp, eğitimin geri kalanından izole edilmesini sağlar.



Toplulaştırma (Aggregating) Aşaması

Ormandaki tüm ağaçlar eğitildikten sonra, yeni bir veri noktası geldiğinde her ağaç kendi tahminini yapar.

Bu tahminler daha sonra birleştirilir (aggregated).

Sınıflandırma problemlerinde bu birleştirme işlemi Çoğunluk Oylaması (Majority Vote) ile yapılır.



Çoğunluk Oylaması (Majority Vote)

Eğer ormanda 100 ağaç varsa, ve yeni bir örnek için 60 ağaç 'Sınıf A' ve 40 ağaç 'Sınıf B' tahmin ediyorsa, Rastgele Orman'ın nihai sonucu 'Sınıf A' olur. Bu basit ancak etkili oylama sistemi, tekil hataları ortadan kaldırır.

Bagging'in Temel Faydası: Varyansı Düşürme

Tek bir Karar Ağacı yüksek varyansa (overfitting) sahiptir, yani küçük veri değişikliklerine aşırı duyarlıdır.

Rastgele Orman, bu tekil ağaçların yüksek varyansını 'ortalama alarak' (aggregation) düşürür.

Sonuç: Çok daha stabil ve güvenilir bir model.

Rastgeleliğin İkinci Kaynağı: Özellik Rastgeleliği

Normal bir Karar Ağacı, bir düğümü bölerken en iyi ayırıcı değişkeni bulmak için TÜM özellikleri analiz eder.

Bu, yüksek oranda korelasyonlu (ilişkili) ağaçlar oluşmasına neden olabilir.



Özellik Rastgeleliği Nasıl Çalışır?

Rastgele Orman, her bir düğümde, özelliklerin sadece rastgele bir alt kümesini dikkate alır.

Örneğin, 30 özellik varsa, her düğüm bölünmesinde sadece rastgele seçilen 5 tanesi analiz edilir.

Bu hiperparametre (`max_features`) genellikle algoritma tarafından belirlenir (örneğin karekökü kadar).

Neden Özellik Rastgeleliği Kullanılır?

Eğer veri setinde çok güçlü bir 'baskın' özellik varsa, tüm ağaçlar ilk bölünmelerini bu baskın özellik üzerinden yapmaya eğilimlidir. Bu, ağaçları birbirine benzer (correlated) hale getirir. Özellik rastgeleliği, baskın özelliğin her zaman seçilmesini engeller ve daha çeşitli ağaçlar (de-correlated) oluşmasını sağlar.

Rastgele Orman: Kapsamlı Tanım

Rastgele Orman, hem veri noktalarında (Bagging) hem de özelliklerde (Feature Randomness) rastgelelik kullanan bir topluluk modelidir. Bu ikili rastgelelik, modelin yüksek genelleme yeteneği sunmasını sağlar. Model yüksek varyanslı tek ağaç yerine, düşük varyanslı bir 'orman' oluşturur.

Out-of-Bag (OOB) Skoru: Giriş

Bootstrap işlemi sayesinde, Rastgele Ormanlar'ın sunduğu benzersiz bir performans metriği vardır: OOB Skoru.
Bu skor, cross-validation gibi ek doğrulama yöntemlerine ihtiyaç duymadan model performansını ölçer.



OOB Verisinin Oluşumu

Her ağaç, eğitim verisinin tamamını görmez.
Bootstrap örnekleme sırasında rastgelelik nedeniyle, veri setinin yaklaşık %37'si her zaman dışarıda kalır (Out-of-Bag verisi).
Bu %37'lik kısım, ilgili ağacın eğitimi sırasında hiç kullanılmamıştır.

OOB Verisinin Test Seti Olarak Kullanımı

Eđitimi tamamlanan her ağaç, kendi OOB verisi için bir test seti görevi görür. Modelin eğitimi bittikten sonra, bu dışarıda kalan veriler kullanılarak o ağaç için bir doğruluk skoru hesaplanır. Tüm ağaçların OOB tahminlerinin ortalaması alınarak nihai OOB Skoru elde edilir.



OOB Skorunun Önemi

OOB skoru, modelin eğitim verisi üzerinde değil, eğitim sırasında hiç görmediği veri üzerindeki genelleme yeteneğini gösterir.
Bu, modelin ne kadar aşırı öğrendiğine dair erken ve güvenilir bir ipucu sunar.



Haftanın Veri Seti: Wine Quality Dataset

Bu hafta, Portekiz 'Vinho Verde' şaraplarına (kırmızı ve beyaz) ait fizikokimyasal özellikleri inceleyeceğiz.

Veri seti, Kaggle veya UCI deposu gibi halka açık kaynaklardan elde edilebilir. Bu veri seti, dengeleyici olmayan (imbalanced) yapıdaki verilerle çalışmak için pedagojik olarak önemlidir.



Fizikokimyasal Özellikler

Veri seti toplamda 11 adet girdi (fizikokimyasal) özelliği içerir. Bunlar arasında sabit asitlik, uçucu asitlik, sitrik asit, kalıntı şeker, klorürler, serbest kükürt dioksit, toplam kükürt dioksit, yoğunluk, pH, sülfatlar ve alkol bulunur.

Hedef Değişken: Kalite Puanı (Quality)

Hedef değişken, duysal uzmanlar tarafından verilen 1'den 10'a kadar bir kalite puanıdır.
Bu, başlangıçta bir regresyon veya çok sınıflı sınıflandırma problemi olarak ele alınabilir.

Veri Seti Yapısı Özeti

Girdi (Özellikler): 11 adet fizikokimyasal özellik.

Çıktı (Hedef): 1 adet 'quality' (kalite) hedef değişkeni.

Amacımız: 11 kimyasal özelliğe dayanarak şarabın kalitesini tahmin etmek.



Pedagojik Önem 1: Özellik Önemi (Feature Importance)

Bu veri setinin seçilme nedenlerinden biri, hangi kimyasal özelliğin kaliteyi en çok etkilediğini görmektir.

Bir uzmanın aksine, biz alkolün mü, şekerin mi yoksa sülfatların mı daha kritik olduğunu bilmiyoruz.

Rastgele Orman, Karar Ağacı'ndan daha stabil ve güvenilir bir özellik önem sıralaması sunar.



Pedagojik Önem 2: Dengesiz Sınıf Yapısı

Şarap kalite puanları (1-10) genellikle çok dengesizdir.
Çoğu şarap ortalama puanlar (5, 6, 7) alırken, çok az şarap çok yüksek (9-10) veya çok düşük (1-2) puan alır.
Bu, makine öğrenimi modellerinin çoğunluk sınıfına eğilimli olmasına neden olabilir.



Problem Dönüşümü: İkili Sınıflandırma

Dengesiz sınıf yapısını daha yönetilebilir hale getirmek için problem ikili (binary) bir sınıflandırma problemine dönüştürülür.
Bu, yüksek lisans düzeyinde yaygın bir yaklaşımdır.



İkili Sınıflandırma Kuralı

Dönüşüm genellikle şu şekilde yapılır:

Eğer Puan 5 veya daha düşük ise, şarap 'Kötü' (0) olarak etiketlenir.

Eğer Puan 6 veya daha yüksek ise, şarap 'İyi' (1) olarak etiketlenir.

Uygulama Ortamı: Google Colab ve Python

Modeli kurmak ve eğitmek için popüler Python kütüphaneleri kullanılacaktır. Veri manipülasyonu için pandas, modelleme için scikit-learn (sklearn) kütüphanesi kullanılacaktır. Çalışma ortamı olarak Google Colab tercih edilir.



Verinin Yüklenmesi ve İlk İşlemler

Veri seti (.csv formatında) pandas kütüphanesi kullanılarak yüklenir.
`pandas.read_csv()` komutu veri setini bir DataFrame yapısına dönüştürür.
Bu aşamada veri setinin ilk satırları incelenir ve eksik veri kontrolü yapılır.



Veri Ön İşleme: Hedef Değişken Dönüşümü

'quality' hedef değişkeni, daha önce açıklanan pedagojik nedenlerle ikili bir sınıfa (0 veya 1) dönüştürülmelidir.
Bu, genellikle bir lambda fonksiyonu veya koşullu atama kullanılarak gerçekleştirilir.



Modelin Kurulması: Sınıflandırıcının Çağrılması

Rastgele Orman modelini kullanmak için scikit-learn kütüphanesindeki `sklearn.ensemble` modülü içinden `RandomForestClassifier` sınıfı çağrılır. Bu, sınıflandırma görevleri için özel olarak tasarlanmıştır.

Hiperparametre Ayarları I: n_estimators

n_estimators parametresi, ormanda yetiştirilecek bağımsız ağaç sayısını belirtir.

Tipik olarak 100, 200 veya daha yüksek değerler kullanılır.

Kaynakta 100 adet ağaç kullanılması önerilmiştir.



Hiperparametre Ayarları II: max_features

max_features parametresi, her düğümü bölerken rastgele düşünülecek özelliklerin sayısını kontrol eder.

'sqrt' (karekök) değeri, toplam özellik sayısının karekökü kadar özelliğin rastgele seçileceği anlamına gelir.

Bu, ağaçların korelasyonunu azaltmak için kritik bir ayardır.

Hiperparametre Ayarları III: OOB Skorunu Aktifleştirme

Modelin eğitim sırasında kendi içindeki test metriklerini hesaplayabilmesi için `oob_score` parametresi 'True' olarak ayarlanmalıdır. Bu ayar, model eğitimi bittikten sonra OOB skoruna ulaşmamızı sağlar.



Modelin Eğitimi (Fitting)

Kurulan model, `fit(X_train, y_train)` komutu ile eğitim verileri (özellikler ve hedef değişken) üzerinde eğitilir.
Bu aşamada 100 adet bağımsız Karar Ağacı, Bagging ve Özellik Rastgeleliği kullanılarak oluşturulur.



Model Çıktılarının Görselleştirilmesi

Eğitilmiş bir Rastgele Orman modelinin en değerli çıktılarından biri, Özellik Önem Sıralamasıdır.

Amacımız, modelin şarap kalitesini tahmin ederken hangi fizikokimyasal özelliklere daha fazla 'baktığını' anlamaktır.

Özellik Önemine Erişim

Özellik önem skorları, eğitilmiş modelin `feature_importances_` öz niteliği (attribute) üzerinden elde edilir.
Bu öz nitelik, 11 özellik için bir önem skoru listesi (array) döndürür.



Sıralama ve Görselleştirme Hazırlığı

Elde edilen önem listesi, `pandas.Series` yapısına dönüştürülmelidir. Bu, her skoru ilgili özellik adıyla eşleştirmeyi sağlar. daha sonra `sort_values()` komutu ile azalan önem sırasına göre sıralanır.

Çubuk Grafik Oluşturma

Sıralanmış özellik önem skorları, `matplotlib.pyplot.bar()` veya `pandas.plot.bar()` kullanılarak bir yatay veya dikey çubuk grafik olarak görselleştirilir.

Bu grafik, hangi özelliklerin model tahminine en çok katkı sağladığını netleştirir.



Özellik Önem Sıralaması Yorumu

Tipik bir senaryoda, bu grafiğin 'alcohol' (alkol) ve 'sulphates' (sülfatlar) gibi özellikleri en üst sıralara taşınması beklenir. Bu, modelin kimyasal girdiler arasındaki karmaşık ve doğrusal olmayan ilişkileri başarıyla yakaladığını gösterir.



Rastgele Ormanlar'ın genelleme yeteneğini ölçmek ve aşırı öğrenmeyi kontrol etmek için çift yönlü bir doğrulama yaklaşımı kullanılır:

1. Out-of-Bag (OOB) Skoru
2. Test Seti Skoru



Değerlendirme 1: OOB Skoru Çekilmesi

Model eğitimi tamamlandıktan sonra, daha önce 'True' olarak ayarlanan `oob_score` parametresinin sonucu çekilir.
bunun için `model.oob_score_` özneliği çağrılır.
Bu skor, modelin eğitim sırasında hiç görmediği %37'lik veri üzerindeki doğruluğu temsil eder.

Değerlendirme 2: Test Seti Skoru

Modelin, eğitimden tamamen ayrı tutulan Test Seti (X_{test}) üzerindeki performansı ölçülür.

Bu, `model.score( $X_{\text{test}}$ ,  $y_{\text{test}}$ )` komutu ile yapılır.

Bu skor, modelin gelecekteki, bilinmeyen verilere ne kadar iyi genelleneceğini gösterir.



Genelleme Kontrolü: Aşırı Öğrenme Teyidi

Modelin aşırı öğrenme yapmadığını güçlü bir şekilde teyit etmek için OOB skoru ile Test Seti skorunun karşılaştırılması gerekir. Beklenti, bu iki skorun birbirine çok yakın çıkmasıdır (Örn. OOB: 0.85, Test: 0.86).



Stabilite ve Genelleme Yeteneđi

Skorların yakınlıđı, Rastgele Orman modelinin yüksek genelleme yeteneđine sahip olduđunu ve tek bir Karar Ađacı'nın aksine aşırı öğrenme tuzađına düşmediđini gösterir.

Bu stabilite, topluluk öğrenmesinin temel avantajıdır.



Sınıflandırma Raporu (classification_report)

Nihai performans analizi için, classification_report kullanılarak daha detaylı metrikler incelenir.

Bu rapor, 'İyi' (1) ve 'Kötü' (0) şarap sınıfları için ayrı ayrı metrikler sunar.



Dengesiz Veride Metriklerin Önemi

Veri setimiz dengesiz olduğu için (daha fazla ortalama kaliteli şarap var), sadece doğruluk (accuracy) yeterli değildir. Precision (Kesinlik), Recall (Hassasiyet) ve F1-Score metriklerinin incelenmesi zorunlu hale gelir. Bu metrikler, modelin hangi sınıfta daha başarılı olduğunu (örneğin azınlık sınıfı olan 'Çok İyi' şarapları ne kadar iyi yakaladığını) gösterir.

Precision (Kesinlik) Detayı

Kesinlik: Modelin 'iyi' dediği şarapların gerçekte ne kadarının 'iyi' olduğunu gösterir.

Yüksek kesinlik, yanlış pozitif oranının düşük olduğu anlamına gelir.



Recall (Hassasiyet) Detayı

Hassasiyet: Gerçekte 'iyi' olan tüm şarapların ne kadarını modelin doğru bir şekilde yakaladığını gösterir.
Düşük hassasiyet, çok sayıda yanlış negatifiin olduğu anlamına gelir.



F1-Score Detayı

F1-Score, Precision ve Recall'un harmonik ortalamasıdır. Dengesiz veri setlerinde, model performansının tek ve adil bir ölçüsünü sağlamak için sıklıkla F1-Score kullanılır.



Random Forest'in Regresyon Uygulamaları

Burada sınıflandırma yaptık, ancak Rastgele Ormanlar regresyon problemleri için de kullanılabilir (RandomForestRegressor).
Temel fark, tahminlerin birleştirilmesidir: Regresyonda, çoğunluk oylaması yerine tüm ağaçların tahminlerinin ortalaması alınır.

RF Algoritmasının Avantajları

Yüksek doğruluk ve genelleme yeteneği sunar.
Aşırı öğrenmeye karşı son derece dirençlidir.
Veri ölçeklendirme (normalization) gerektirmez.
Eksik verileri iyi işleyebilir (Bazı uygulamalarda).
Özellik önemini doğal olarak sağlar.

RF Algoritmasının Dezavantajları

Hesaplama maliyeti yüksektir, özellikle çok sayıda ağaç ($n_estimators$) kullanıldığında.

Tek bir Karar Ağacı'na göre daha az yorumlanabilir (kutu gibi çalışır).
Büyük veri setlerinde eğitim süresi uzayabilir.



Model Kalibrasyonu: Hiperparametre Optimizasyonu

Modelin performansını optimize etmek için `n_estimators`, `max_features` ve `max_depth` gibi hiperparametreler Grid Search veya Random Search yöntemleriyle ayarlanmalıdır.

Bu, en iyi OOB skorunu veren parametre kombinasyonunu bulmaya yardımcı olur.



Gelecek Haftaya Bakış

Bu hafta, Bagging tabanlı topluluk öğrenmesini inceledik.
Gelecek hafta, performansını daha da artırmak için farklı bir topluluk öğrenme tekniği olan Boosting (Yükseltme) algoritmalarını inceleyeceğiz.
Özellikle Gradient Boosting ve XGBoost gibi güçlü modeller ele alınacaktır.



Özet: Rastgele Orman Temel Kavramları

Rastgele Ormanlar (RF) aşırı öğrenmeyi önlemek için Bagging ve Özellik Rastgeleliği kullanır.

Bagging, yerine koyarak rastgele örneklem almayı içerir (Bootstrap).

Özellik Rastgeleliği, her düğümde sadece rastgele bir özellik alt kümesinin dikkate alınmasını sağlar.



Özet: Değerlendirme ve Uygulama

Out-of-Bag (OOB) skoru, çapraz doğrulama olmadan genelleme yeteneğini ölçer.

Şarap Kalitesi veri setinde, problem dengesizliği nedeniyle ikili sınıflandırmaya dönüştürme yapıldı.

Özellik Önem sıralaması (feature_importances_), en etkili kimyasal özellikleri (örn. alkol, sülfatlar) ortaya çıkarır.

Performans değerlendirmesinde OOB ve Test skoru yakınlığı aşırı öğrenme olmadığını kanıtlar.



Rastgele Ormanlar (Random Forest)

Süleyman **EZDEMİR**

suleyman.ezdemir@giresun.edu.tr

