

K-Ortalamlar (K-Means)

Veri Mad. - Hafta 13

K-Ortalamlar (K-Means) Kümeleme Analizi

Bu hafta, en popüler kümeleme algoritmalarından biri olan K-Means'i derinlemesine inceleyeceğiz.

Algoritmanın teorik temelleri, çalışma adımları ve amaç fonksiyonu ele alınacaktır.

Pratik bir vaka çalışması olan Alışveriş Merkezi Müşteri (Mall Customers) veri setini kullanarak segmentasyon uygulamasını gerçekleştireceğiz.

Elde edilen sonuçların Silhouette Skoru ile akademik olarak nasıl değerlendirileceğini öğreneceğiz.



Gözetimsiz Öğrenme Perspektifi

K-Means, makine öğreniminin gözetimsiz öğrenme (unsupervised learning) alanına aittir.

Gözetimsiz öğrenmede, elimizde 'gerçek etiketler' (ground truth) veya hedef değişken (Y) bulunmaz.

Algoritmanın görevi, veri noktaları arasındaki doğal yapıyı, benzerlikleri ve farklılıkları keşfederek gruplar (kümeler) oluşturmaktır.

Kümeleme, desen keşfi (pattern discovery) ve veri yoğunluğunu anlama açısından kritik öneme sahiptir.



K-Means Kümelemesine Giriş

K-Means (K-Ortalamalar), en basit, en hızlı ve en popüler kümeleme algoritmalarından biridir.

Bu, bir 'merkez (centroid) tabanlı' yaklaşımdır.

Temel amacı, veri setini önceden belirlenmiş 'K' sayıda kümeye bölmektir. Kümelerin oluşturulmasında, her veri noktasının kendine en yakın küme merkezine atanması ilkesi kullanılır.



Merkez Tabanlı Kümeleme Yaklaşımı

K-Means, her kümenin geometrik bir 'merkezi' (centroid) olacak şekilde çalışır. Centroid, kümedeki tüm veri noktalarının aritmetik ortalamasını (mean) temsil eder.

Algoritma, bu merkezleri optimize ederek kümelerin sıkılığını (compactness) maksimize etmeye çalışır.

Bu merkezler, kümenin temsilci noktaları olarak görev yapar ve kümenin karakteristik özelliklerini belirler.



Bölüm 2: K-Means Algoritmasının Adımları

K-Means, küme merkezlerini bulmak için yinelenen (iterative) bir süreç kullanır. Bu süreç, iki temel adımın (Atama ve Güncelleme) merkezler 'konum değiştiremez hale gelene kadar' tekrarlanmasına dayanır. Bu tekrarlama, algoritmanın hedeflenen minimum noktaya ulaşmasını sağlar (yakınsama - convergence).



Adım 1: Başlatma (Initialization)

Algoritmanın ilk adımı, 'K' adet küme merkezini veri uzayına yerleştirmektir. Bu yerleştirme başlangıçta rastgele yapılabilir (Simple K-Means). Daha akıllı ve yaygın bir başlatma yöntemi olan K-Means++ ise, merkezlerin birbirine daha uzak olacak şekilde seçilmesini sağlayarak algoritmanın daha hızlı ve doğru yakınsamasını destekler. Başlangıç merkezlerinin konumu, nihai kümeleme sonucunu önemli ölçüde etkileyebilir.



K-Means++ Yöntemi (Akademik Zenginleştirme)

K-Means++ yöntemi, rastgele seçimden kaynaklanan yerel minimum riskini azaltmak için tasarlanmıştır.

İlk merkez rastgele seçilir.

Sonraki her merkez, mevcut merkezlere olan uzaklığı yüksek olan veri noktalarından olasılıksal olarak seçilir.

Bu, başlangıç merkezlerinin birbirinden daha dağınık ve temsili olmasını sağlar, bu da algoritmanın performansını artırır.



Adım 2: Atama (Assignment)

Her veri noktası, mevcut küme merkezleri arasından kendisine en yakın olana atanır.

Bu 'en yakın' kavramı genellikle Öklid mesafesi (Euclidean distance) kullanılarak belirlenir.

Bu adım, tüm veri setini 'K' sayıda geçici kümeye ayırır.



Mesafe Metriği: Öklid Mesafesi

Öklid mesafesi, iki nokta arasındaki düz çizgi uzaklığını hesaplayan standart metottur.

Formül: $d(x, y) = \sqrt{\sum (x_i - y_i)^2}$.

K-Means, uzaklık tabanlı çalıştığı için, özelliklerin ölçeklerinin aynı olması kritik öneme sahiptir (Ön işleme zorunluluğu).

Öklid mesafesi dışında Manhattan (L1) veya kosinüs benzerliği gibi metrikler de kullanılabilir, ancak K-Means standart olarak Öklid'i tercih eder.

Adım 3: Güncelleme (Update)

Atama adımından sonra, her küme için yeni bir merkez (centroid) hesaplanır. Yeni merkez, o kümeye atanmış olan tüm noktaların ortalaması (mean) alınarak bulunur.

Bu, kümenin yeni ağırlık merkezine taşınması anlamına gelir ve Atalet (Inertia) değerini azaltma hedefiyle yapılır.



İterasyon ve Yakınsama (Convergence)

Atama (Adım 2) ve Güncelleme (Adım 3) adımları sürekli olarak tekrarlanır. Döngü, küme merkezleri artık konum değiştirmez hale gelene kadar devam eder.

Bu noktaya 'yakınsama' (convergence) denir ve K-Means algoritmasının çalışması sona erer.

Yakınsama sağlandığında, her nokta ait olduğu kümeye en yakın mesafededir.

Bölüm 3: Amaç Fonksiyonu ve Optimizasyon

K-Means'in temel optimizasyon hedefi, 'Amaç Fonksiyonu'nu minimize etmektir.

Bu amaç fonksiyonu, Atalet (Inertia) veya WCSS (Within-Cluster Sum of Squares) olarak bilinir.

WCSS, 'Küme İçi Kareler Toplamı' anlamına gelir ve küme içi tutarlılığı (cohesion) ölçer.



Atalet (Inertia / WCSS) Tanımı

Atalet, her veri noktasının, kendi atandığı küme merkezine olan uzaklıklarının kareleri toplamıdır.

Matematiksel olarak: $\sum_{i=1}^K \sum_{x \in C_i} \|x - \mu_i\|^2$

Daha düşük atalet değeri, kümelerin daha yoğun (compact) ve sıkı olduğunu gösterir.

Algoritma, her iterasyonda bu WCSS değerini düşürmeye çalışır.

K-Means'in Zorlukları ve Kısıtlamaları

K-Means, basitliğine rağmen bazı önemli zorluklara sahiptir. Bu zorluklar, modelin doğru sonuç vermesini engelleyebilir.

1. 'K' Değerinin Önceden Belirlenmesi.
2. Başlangıç Merkezlerinin Seçimine Duyarlılık.
3. Yalnızca Küresel Şekilli Kümelerle Başarı.
4. Aykırı Değerlere Duyarlılık (Ortalama Tabanlı Yapıdan dolayı).

Zorluk 1: Optimal 'K' Değeri

K-Means'in en büyük zorluğu, küme sayısı olan 'K' değerinin kullanıcı tarafından önceden belirlenmesi gerekliliğidir.

Yanlış K değeri seçimi, anlamsız veya ticari değeri olmayan segmentlere yol açabilir.

Bu sorunu çözmek için Elbow Method (Dirsek Yöntemi) ve Silhouette Score gibi yöntemler kullanılır.



Zorluk 2: Başlangıç Hassasiyeti

Algoritma, başlangıç merkezlerinin seçimine karşı hassastır. Rastgele bir başlangıç seçimi, algoritmanın küresel optimum yerine bir 'lokal minimuma' takılmasına neden olabilir. Bu, farklı başlatmaların tamamen farklı kümeleme sonuçları vermesi demektir. K-Means++ ve birden çok rastgele başlatma (`n_init` parametresi) kullanmak bu sorunu azaltır.



Zorluk 3: Küresel (Spherical) Kısıtlama

K-Means, geometrik merkezler ve Öklid mesafesi kullandığı için, yalnızca küresel (spherical) şekle sahip ve benzer yoğunluktaki kümeleri bulmakta başarılıdır.

Uzun, eliptik veya iç içe geçmiş küme yapılarını (non-convex shapes) tanımlayamaz.

Bu gibi durumlarda, DBSCAN veya Mean-Shift gibi farklı kümeleme algoritmaları daha uygun olabilir.



Bölüm 4: Vaka Çalışması: Mall Customers Dataset

Bu hafta pratik uygulama için 'Mall Customers Dataset' (Alışveriş Merkezi Müşterileri Veri Seti) kullanılacaktır.

Bu veri seti, müşteri segmentasyonunun görsel olarak incelenmesi için pedagojik öneme sahiptir.

Segmentasyon, pazarlama ve iş stratejileri için kilit bir analitik yaklaşımdır.



Veri Setinin Yapısı

Veri seti 200 örneklem (müşteri) ve 5 özellik içerir.

Özellikler şunlardır:

1. Müşteri ID
 2. Cinsiyet
 3. Yaş
 4. Yıllık Gelir (Annual Income - k\$ cinsinden)
 5. Harcama Skoru (Spending Score - 1'den 100'e).
- Harcama Skoru, müşterinin alışveriş merkezinde ne kadar aktif ve çok harcama yaptığının normalize edilmiş bir ölçütüdür.

Segmentasyonun Odağı

K-Means modelini oluştururken sadece iki anahtar özellik kullanılacaktır:

1. Annual Income (Yıllık Gelir)
2. Spending Score (Harcama Skoru)

Bu iki özelliğin seçilme nedeni, 2 boyutlu bir düzlemde çizdirildiklerinde 'insan gözüyle bile kolayca görülebilen' belirgin segmentler oluşturmalarıdır.

Görsel Segmentasyonun Gücü

Bu veri seti, K-Means'in görsel olarak ne kadar başarılı olduğunu göstermek için mükemmel bir 2D senaryo sunar.
Veri noktaları, gelir ve harcama skoruna dayalı olarak kümeler halinde doğal bir şekilde gruplanır.
Bu net ayırım, algoritmanın kümeleme mantığını anlamayı kolaylaştırır.

Beklenen 5 Müşteri Segmenti

Verinin yapısı gereği, K-Means algoritmasının bulması beklenen 5 belirgin müşteri segmenti bulunmaktadır:

1. Düşük Gelir – Düşük Harcama (Tutumlu)
2. Düşük Gelir – Yüksek Harcama (Genç/Harcamayı Seven)
3. Orta Gelir – Orta Harcama (Standart)
4. Yüksek Gelir – Düşük Harcama (Dikkatli/Zengin)
5. Yüksek Gelir – Yüksek Harcama (Hedef Kitle/Pazarlamacıların Rüyası).

Segment 1: Tutumlular (Frugal)

Özellikler: Hem yıllık gelirleri düşüktür hem de alışveriş merkezinde düşük harcama eğilimi gösterirler.

Ticari Anlamı: Bu kitle genellikle düşük öncelikli hedeftir. Onlara yönelik yüksek fiyatlı lüks ürün kampanyaları etkisiz olacaktır.

Strateji: Temel ihtiyaçlara odaklanan, indirimli ürünler veya ekonomik paketler sunulabilir.

Segment 2: Hevesliler (Spenders)

Özellikler: Gelirleri düşük olmasına rağmen, harcama skorları yüksektir. Bu, genellikle genç, trendlere düşkün veya bütçesini aşan harcamalar yapan bir kitleyi temsil edebilir.

Ticari Anlamı: Riskli ancak potansiyeli yüksek bir gruptur. Satın alma kararları duygusal olabilir.

Strateji: Kolay erişilebilir kredi veya taksit seçenekleri sunmak bu grubun harcamasını maksimize edebilir.



Segment 3: Standartlar (Middles)

Özellikler: Hem gelir hem de harcama skorları ortalama düzeydedir. En büyük popölasyonu temsil eden, öngörülebilir bir kitledir.

Ticari Anlamı: İstikrarlı bir pazar payı sağlarlar.

Strateji: Genel promosyonlar ve standart ürün teklifleri bu gruba uygundur.

Sadakat programlarıyla bağlılıkları artırılabilir.



Segment 4: Dikkatlılar (Cautious Affluent)

Özellikler: Gelirleri çok yüksektir, ancak harcama skorları düşüktür. Varlıklı ancak tutumlu veya paranın değerini bilen bir kitleyi temsil eder.

Ticari Anlamı: Potansiyel büyük, ancak erişimi zor bir gruptur.

Strateji: Bu kitle, kaliteye ve uzun vadeli değere önem verir. Yatırım veya lüks hizmetlere odaklanmak, bireysel danışmanlık hizmetleri sunmak etkili olabilir.

Segment 5: Hedef Kitle (Target Market)

Özellikler: Hem yıllık gelirleri hem de harcama skorları en yüksek seviyededir.

Ticari Anlamı: En değerli, en kârlı müşteri grubudur. Pazarlama çabalarının birincil hedefidir.

Strateji: Özel teklifler, VIP hizmetler, kişiselleştirilmiş lüks deneyimler ve en yeni ürünlere erken erişim sağlanmalıdır. Müşteri tutma (retention) bu grup için hayati önem taşır.



Bölüm 5: Python Uygulaması (Scikit-learn)

Mall Customers veri setini kullanarak K-Means uygulamasını Google Colab ve Python kütüphaneleri (pandas, scikit-learn, matplotlib) üzerinden gerçekleştireceğiz.

Uygulama dört ana aşamadan oluşur:

1. Veri Yükleme ve Özellik Seçimi.
2. Veri Ön İşleme (Ölçeklendirme).
3. Optimal K değerini bulma (Elbow Method).
4. Model Eğitimi ve Etiketleme.

Verinin Yüklenmesi

Uygulamanın başlangıcında, .csv formatındaki veri seti pandas kütüphanesi kullanılarak yüklenir.

'pd.read_csv('Mall_Customers.csv')' komutu ile veri, DataFrame yapısına aktarılır.

Verinin ilk birkaç satırını kontrol etmek (data inspection) ve eksik değerleri kontrol etmek ilk zorunlu adımlardır.



Özellik Seçimi ve X Değişkeni

Modelde sadece 'Annual Income' ve 'Spending Score' sütunları kullanılacağı için, bu sütunlar seçilerek bağımsız değişken matrisi 'X' oluşturulur. Bu aşama, modelin sadece ilgili iki boyut üzerinde kümeleme yapmasını sağlar.



Ön İşleme: Ölçeklendirme Zorunluluğu

K-Means, uzaklık tabanlı (Euclidean distance) bir algoritma olduğu için özelliklerin aynı ölçekte olması hayati önem taşır.

Mall Customers veri setinde 'Yıllık Gelir' 15.000\$ - 137.000\$ aralığındayken, 'Harcama Skoru' 1 - 100 aralığındadır.

Bu ölçek farkı, gelirin mesafeyi domine etmesine neden olur, bu da harcama skorunun etkisini düşürür.



StandardScaler Uygulaması

Ön işlemeyi gerçekleştirmek için 'StandardScaler' kullanılır. StandardScaler, veriyi ortalaması 0 ve standart sapması 1 olacak şekilde dönüştürür (Z-Skoru normalizasyonu). Bu işlem, tüm özelliklerin aynı ağırlığa sahip olmasını ve kümeleme sonuçlarının mesafe yerine desenlere dayanmasını sağlar.



Optimal 'K' Değerini Bulma

Kullanıcı tarafından önceden belirlenmesi gereken 'K' sayısını (küme sayısını) objektif olarak seçmek için Dirsek Yöntemi kullanılır. Bu yöntem, farklı K değerleri için elde edilen WCSS/Atalet değerlerini incelemeye dayanır.



Elbow Method: Döngü ve Hesaplama

Elbow Method için 'K' sayısı genellikle 1'den 10'a kadar bir döngüye sokulur. Herk 'K' değeri için bir 'sklearn.cluster.KMeans' modeli eğitilir. Eğitilen her modelden 'model.inertia_' özneliği (WCSS değeri) kaydedilir.

Elbow Grafiğinin Yorumlanması

Toplanan K (X eksen) ve WCSS (Y eksen) değerleri 'plt.plot()' ile çizdirilir. Grafikte WCSS değerinin hızla düşüşünün yavaşladığı, keskin bir kırılmanın yaşandığı nokta aranır. Bu nokta 'dirsek' (elbow) noktası olarak adlandırılır ve optimal küme sayısı 100 olarak seçilir. Mall Customers veri setinde bu kırılma noktası K=5 olarak gözlemlenir.

Nihai Model Eğitimi

Optimal $K=5$ değeri belirlendikten sonra, nihai K-Means modeli kurulur. Model kurulumu sırasında '`n_clusters=5`' ve başlangıç yöntemi olarak '`init='k-means++`' kullanılır. Model, ölçeklendirilmiş veri (`X_scaled`) üzerinde '`fit_predict()`' komutu ile eğitilir.

Model Çıktısı: Küme Etiketleri

'fit_predict(X_scaled)' komutu, hem modeli eğitir hem de veri setindeki her veri noktasının hangi kümeye ait olduğunu etiketler. Etiketler, 0'dan K-1'e (yani 0'dan 4'e) kadar tamsayı değerleridir. Bu etiketler, daha sonra görselleştirme ve performans değerlendirmesi için kullanılır ('model.labels_').



Bölüm 6: Sonuçların Görselleştirilmesi

Görselleştirme, K-Means tarafından bulunan 5 müşteri segmentinin uzayda nasıl konumlandığını haritalandırmayı amaçlar.
Bu, analitik sonuçların iş birimlerine aktarılması için en güçlü yöntemdir.



Matplotlib Scatter Plot Kullanımı

Küme segmentlerini görselleştirmek için 'matplotlib.pyplot.scatter()' fonksiyonu kullanılır.

X eksenini 'Annual Income' (Yıllık Gelir) ve Y eksenini 'Spending Score' (Harcama Skoru) olarak belirleriz.

Ölçeklendirilmiş veriler yerine, sonuçları ticari bağlamda anlamlandırmak için genellikle orijinal (ölçeklendirilmemiş) veriler kullanılır.

Noktalara Renk Atama

Görselleştirmede en kritik adım, her veri noktasının ait olduğu kümeye göre farklı bir renkle boyanmasıdır.

Bu, 'scatter()' fonksiyonuna 'c=model.labels_' parametresi verilerek sağlanır. Matplotlib, bu parametre sayesinde her bir küme etiketine (0, 1, 2, 3, 4) otomatik olarak farklı bir renk atar.



Küme Merkezlerinin Görselleştirilmesi

Küme merkezleri (Centroids), 'kmeans.cluster_centers_' özniteliği kullanılarak elde edilir.

Bulunan bu 5 küme merkezinin koordinatları, aynı dağılım grafiği üzerine eklenir.

Centroidler, küme noktalarından ayrılması için genellikle daha büyük bir işaret ('marker='X') ve belirgin bir renkle ('c='red') çizdirilir.

Görsel Çıktı Analizi

Oluşan görsel çıktı, veri setinin neden bu kadar popüler olduğunu anında gösterir.

Grafik üzerinde 5 segmentin (kümenin) net, belirgin ve ticari olarak anlamlı olduğu ortaya çıkar.

Pazarlamacılar bu görsel haritayı kullanarak hangi segmente hangi stratejinin uygulanacağını hızlıca belirleyebilir.



Segmentasyonun İş Hacmine Etkisi

Müşteri segmentasyonu, geliştirilmiş pazarlama stratejilerinden uzaklaşmayı sağlar.

Her segmente özel fiyatlandırma, ürün teklifi ve iletişim kanalı belirlenir.

Örneğin, 'Yüksek Gelir - Yüksek Harcama' segmentine özel indirimler yerine deneyim odaklı teklifler sunulur.

Bu kişiselleştirme, müşteri sadakatini ve genel harcama hacmini artırır.



Bölüm 7: Performans Değerlendirmesi

Gözetimsiz öğrenmede 'gerçek' etiketler (ground truth) bulunmadığı için, standart sınıflandırma metrikleri (precision, recall, classification_report) kullanılamaz.

Kümeleme performansını değerlendirmek için içsel (intrinsic) metrikler kullanılır.

Bu metrikler, kümenin yapısına (yoğunluk, ayrışma) odaklanır. Silhouette Score, bu amaçla kullanılan en yaygın metriklerden biridir.



Silhouette Score (Siluet Skoru) Giriş

Silhouette Score, bir kümeleme sonucunun ne kadar 'iyi' olduğunu ölçen bir metriktir.

'İyi' bir kümeleme, hem yoğun (cohesive) hem de iyi ayrılmış (separated) kümeler anlamına gelir.

Skor, her veri noktası için hesaplanır ve ardından tüm noktaların ortalaması alınarak genel bir skor elde edilir.



Silhouette Skoru Teorisi: Bağlılık (Cohesion)

Her i noktası için $a(i)$, noktanın kendi kümesindeki diğer noktalara olan ortalama uzaklığıdır.

Bu değer, küme içi yakınlığı veya 'bağlılığı' temsil eder.

İstenen: Kümelemenin iyi olması için $a(i)$ değerinin mümkün olduğunca düşük olması istenir (nokta kendi merkezine ve diğer küme üyelerine yakın olmalıdır).



Silhouette Skoru Teorisi: Ayırışma (Separation)

Her x_i noktası için $b(i)$, noktanın 'en yakın komşu kümedeki' (neighboring cluster) noktalara olan ortalama uzaklığıdır.

Bu değer, kümeler arası uzaklığı veya 'ayırışmayı' temsil eder.

İstenen: Kümelemenin iyi olması için $b(i)$ değerinin mümkün olduğunca yüksek olması istenir (nokta en yakın rakip kümeden uzak olmalıdır).



Silhouette Skoru Formülü

Silhouette Skoru $s(i)$, $a(i)$ ve $b(i)$ değerleri kullanılarak aşağıdaki formülle hesaplanır:

$$s(i) = (b(i) - a(i)) / \max(a(i), b(i))$$

Bu formül, skoru daima -1 ile +1 aralığında tutar.



Silhouette Skoru Yorumlama: +1

Eğer $s(i)$ +1'e yakınsa, bu mükemmel bir kümelemeyi gösterir.
Anlamı: $b(i)$ çok büyüktür ($b(i) \gg a(i)$). Nokta, kendi kümesine çok yakınken, diğer en yakın kümeden çok uzaktadır.
Bu, kümenin yoğun ve rakiplerinden tamamen ayrılmış olduğunu gösterir.



Silhouette Skoru Yorumlama: 0

Eğer $s(i)$ 0'a yakınsa, $a(i)$ ve $b(i)$ değerleri birbirine yakındır ($a(i) \approx b(i)$).

Anlamı: Nokta, kendi kümesinin sınırında veya iki küme arasında bir noktada yer almaktadır.

Bu durum, kümelerin üst üste binmeye başladığını veya sınırlarının belirsizleştiğini gösterir.



Silhouette Skoru Yorumlama: -1

Eğer $s(i)$ -1'e yakınsa, bu çok kötü bir kümelemeyi gösterir.
Anlamı: $a(i)$ çok büyüktür ($a(i) > b(i)$). Nokta, kendi küme merkezinden daha çok, en yakın komşu küme merkezine yakındır.
Basitçe, bu noktanın yanlış kümeye atandığı anlamına gelir.



Uygulama: Scikit-learn ile Hesaplama

Tüm veri noktaları için ortalama siluet skorunu bulmak üzere 'sklearn.metrics' içinden 'silhouette_score()' fonksiyonu çağrılır. Fonksiyon, ölçeklendirilmiş veri (X_{scaled}) ve modelin oluşturduğu küme etiketlerini ('model.labels_') girdi olarak alır. Çıktı, tüm veri setinin ortalama küme kalitesini temsil eden tek bir değerdir.

Elbow ve Silhouette Skorunun Karşılaştırılması

Silhouette Skoru, Elbow Method'un sunduğu K seçimini akademik olarak doğrulamak için kullanılır.

Farklı K değerleri (örneğin $K=4$, $K=5$, $K=6$) için elde edilen ortalama silüet skorları karşılaştırılır.

En yüksek silüet skoruna sahip olan K değeri, en yoğun ve en iyi ayrılmış kümeyi temsil eder.

Mall Customers veri setinde, $K=5$ için elde edilen skorun (örn. 0.55), $K=4$ (örn. 0.49) veya $K=6$ (örn. 0.48) için elde edilen skarlardan daha yüksek olması, $K=5$ 'in optimal seçim olduğunu doğrular.

Algoritma Performansı ve Hesaplama Maliyeti

K-Means algoritması, hesaplama açısından oldukça verimlidir ve büyük veri setlerinde bile hızlı çalışır.

Zaman karmaşıklığı genellikle $O(I \cdot K \cdot N \cdot D)$ olarak ifade edilir, burada I iterasyon sayısı, K küme sayısı, N veri noktası sayısı ve D özellik sayısıdır.

Bu lineer karmaşıklık, K-Means'i birçok endüstriyel uygulama için tercih edilen ilk kümeleme algoritması yapar.



K-Means'in Ölçeklenebilirliği

Geleneksel K-Means tüm veri setini hafızada tutmak zorundadır. Çok büyük veri setlerinde (big data) bu sorun olabilir. Mini Batch K-Means, her iterasyonda veri setinin küçük rastgele alt kümelerini (mini-batch) kullanarak merkezleri günceller. Bu, yakınsama hızını biraz düşürse de, bellek kullanımını optimize eder ve çok daha hızlı çalışır.

Özet ve Temel Çıkarımlar

K-Means, merkez tabanlı, iteratif bir kümeleme algoritmasıdır.

Temel hedefi Atalet (WCSS) değerini minimize etmektir.

Mall Customers veri seti, 2 boyutlu uzayda segmentasyonun görsel gücünü kanıtlar.

Ön işleme (StandardScaler) K-Means için zorunludur.

Optimal K değeri Elbow Method ve Silhouette Score ile belirlenir.

Silhouette Score, kümelerin yoğunluk ve ayrışma kalitesini ölçer ve gözetimsiz öğrenmede kritik bir değerlendirme aracıdır.



Teşekkürler

Bu oturumda K-Means teorisi ve pratik uygulamasını tamamladık.
Unutmayın: Başarılı bir kümeleme analizi, sadece teknik doğrulukla değil, aynı zamanda elde edilen segmentlerin ticari anlamlılığı ile de ölçülür.



K-Ortalamlar (K-Means)

Süleyman **EZDEMİR**

suleyman.ezdemir@giresun.edu.tr

