

Hiyerarşik Kümeleme

Veri Mad. - Hafta 14

Hiyerarşik Kümelemeye Giriş

Bu hafta, K-Means'in sınırlamalarını aşan, verinin içindeki hiyerarşiyi ortaya çıkaran bir kümeleme yöntemine odaklanacağız: Hiyerarşik Kümeleme (Hierarchical Clustering).

Bu yöntem, veriler arasındaki karmaşık, iç içe geçmiş ilişkileri modellemek için idealdir.



K-Means'in Sınırlamaları Nelerdi?

K-Means algoritması başarılı olsa da, temel bir zorunluluğa sahiptir: Küme sayısının ('K') analist tarafından baştan belirlenmesi gerekir. Gerçek dünyadaki verilerin yapısı, 'K' sayısının kesin olarak bilinemediği durumlar yaratır. Ayrıca K-Means, genellikle küresel şekilli gruplar bulmaya eğilimlidir.

Hiyerarşik Kümeleme: Farklı Bir Bakış Açısı

Hiyerarşik Kümeleme, verinin küresel gruplardan daha karmaşık, iç içe geçmiş bir yapıda olduğu durumlar için tasarlanmıştır.

Algoritmanın temel amacı, tek bir kümeleme sonucu vermek yerine, birbiri içinde yuvalanmış (nested) kümelerden oluşan bir yapı, yani bir 'ağaç' üretmektir.

Bu yapı, verinin doğal ilişkilerini gösterir.



Temel Çıktı: Dendrogram

Hiyerarşik kümelemenin asıl çıktısı, tüm birleşme sürecini görselleştiren ağaç diyagramı olan Dendrogram'dır. Dendrogram, hangi veri noktalarının hangi 'mesafede' birleştiğini gösterir. Bu diyagram, optimal küme sayısını belirlememize yardımcı olan kritik araçtır.

Hiyerarşik Kümelemenin İki Ana Yaklaşımı

Hiyerarşik kümeleme algoritmaları iki temel stratejiye ayrılır:

1. Agglomerative (Birleştirici): Aşağıdan yukarıya (Bottom-up) yaklaşım.
2. Divisive (Bölücü): Yukarıdan aşağıya (Top-down) yaklaşım.

Pratikte en yaygın kullanılan ve odaklanacağımız yaklaşım Agglomerative'dir.

Agglomerative Yaklaşım Detayı: Bottom-Up

Agglomerative, 'birleştirici' anlamına gelir ve sürece en küçük birimden başlar. Başlangıç: Her veri noktası kendi başına bir kümedir (N adet küme). Bu, en alt hiyerarşik seviyeyi temsil eder.

Tekrarlı Birleşme: Her adımda, birbirine en yakın olan iki küme bulunur ve birleştirilir.

Sonuç: Bu işlem, en sonunda tüm veriyi içeren tek bir dev küme kalana kadar devam eder.



Divisive Yaklaşım Detayı: Top-Down

Divisive, 'bölücü' anlamına gelir ve sürece en üst hiyerarşik seviyeden başlar. Başlangıç: Tüm veri noktaları tek bir büyük küme olarak kabul edilir. Tekrarlı Bölünme: Her adımda, kümenin içindeki en büyük varyansa sahip olan küme, iki alt kümeye bölünür. Sonuç: Bu işlem, her veri noktasının ayrı bir küme haline gelmesine kadar devam eder.



Kritik Soru: Küme Uzaklığı Nasıl Tanımlanır?

Agglomerative süreçte, hangi iki kümenin birleştirileceğine karar vermek için 'iki küme arasındaki uzaklık' tanımlanmalıdır.

Bu tanım, Bağlantı Kriteri (Linkage Criteria) ile belirlenir ve bu seçim, algoritmanın nihai küme yapısını kökten değiştirir.

Farklı kriterler, farklı geometrik şekillere sahip kümeleri bulmaya odaklanır.



1. Bağlantı Kriteri: Single Linkage (Tekil Bağlantı)

Tanım: İki küme arasındaki en yakın noktaların mesafesidir. Yani, C1 kümesindeki bir nokta ile C2 kümesindeki bir nokta arasındaki minimum mesafedir.

Avantajı: Düzensiz şekilli veya uzun, zincirleme (chaining) kümeleri bulmaya eğilimlidir.

Dezavantajı: Gürültüye (noise) karşı hassastır ve kümeler arasında köprüler oluşturabilir.



2. Bağlantı Kriteri: Complete Linkage (Tam Bağlantı)

Tanım: İki küme arasındaki en uzak noktaların mesafesidir. Yani, C1 kümesindeki bir nokta ile C2 kümesindeki bir nokta arasındaki maksimum mesafedir.

Avantajı: Daha yoğun ve küresel (compact, spherical) kümeler bulur.

Dezavantajı: Aykırı değerlere (outliers) karşı çok hassastır ve küme sınırlarını aşırı daraltabilir.



3. Bağlantı Kriteri: Average Linkage (Ortalama Bağlantı)

Tanım: İki küme arasındaki tüm noktalar arasındaki ortalama mesafedir. Bu yöntem, Single ve Complete Linkage'in uç noktalarını dengeleyen bir yaklaşımdır.

Avantajı: Outlier'lara karşı daha dayanıklı ve genellikle iyi yuvarlak kümeler üretir.



4. Bağlantı Kriteri: Ward Linkage (Ward Bağlantısı)

Tanım: En popüler kriterdir. İki kümeyi birleştirmenin, toplam WCSS'yi (Within-Cluster Sum of Squares, K-Means'deki atalet) en az artıran seçeneği tercih eder.

Bu, birleşme sonrası küme içi varyansı minimumda tutmayı hedefler.

Ward metodu genellikle iyi ayrılmış, küresel şekilli kümeler üretir ve Seeds veri setinde kullanılan metottur.

Ward Kriteri ve Inertia Kavramı

WCSS, her kümedeki noktaların küme merkezine olan mesafelerinin karelerinin toplamıdır.

Ward metodu, C1 ve C2 kümeleri birleştirildiğinde (C_yeni), C_yeni kümesinin WCSS değerinin, C1 ve C2'nin ayrı WCSS değerlerine göre artışını hesaplar. Algoritma, bu artışı (inertia artışı) en küçük tutan birleşmeyi seçer.



Dendrogram: Hiyerarşik Yapının Haritası

Dendrogram, hiyerarşik kümeleme algoritmasının çıktı matrisinin (Z matrisi) görsel temsilidir.

Yatay Eksen: Bireysel örnekleri veya daha küçük kümeleri temsil eder.

Dikey Eksen (Mesafe): Küme birleşmelerinin gerçekleştiği mesafeyi (veya dissimilarity'yi) gösterir.

Bu yapı, hangi kümelenme seviyesinde duracağımızı belirlememizi sağlar.

Vaka Çalışması: Seeds Dataset (Tohumlar)

Bu haftanın uygulamalı veri seti, Seeds Dataset'tir.

Bu veri seti, üç farklı buğday türüne ait tohumların (Kama, Rosa, Canadian) geometrik özelliklerini içerir.

Hedefimiz, bu özellikleri kullanarak tohumları biyolojik yapılarına göre otomatik olarak gruplandırmaktır.

Seeds Veri Setinin Yapısal Özellikleri

Örneklem Sayısı: Veri seti toplam 210 örneklem içerir.

Özellik Sayısı: 7 sayısal özellik mevcuttur (Alan, Çevre, Kompaktlık vb.).

Hedef Sınıflar (Gerçek Etiketler): Kama, Rosa ve Canadian olmak üzere 3 hedef sınıf vardır.

Bu sınıflar gözetimsiz bir problemde çalıştığımız için eğitimde kullanılmaz, yalnızca modelin başarısını doğrulamak için en sonda kullanılır.

Seeds Veri Setinin Pedagojik Önemi

Seeds veri setinin seçilmesinin nedeni, içerdği hiyerarşik yapıdır. Buğday türleri biyolojik olarak birbiriyle ilişkilidir; örneğin Kama ve Rosa genetik olarak daha yakın olabilirler (bir ana grup) ve Canadian onlardan daha farklı olabilir. Bu tür iç içe geçmiş ilişkiler, K-Means tarafından zor bulunur ancak Dendrogram ile ideal olarak görselleştirilebilir.

Uygulama Adımlarına Genel Bakış

Uygulama süreci şu ana adımlardan oluşur:

1. Veri Yükleme ve Özellik Ayırma (Pandas).
2. Ön İşleme (StandardScaler).
3. Linkage Matrisi Oluşturma (SciPy).
4. Optimal Küme Sayısını Belirleme (Dendrogram Analizi).
5. Küme Etiketlerini Üretme (Scikit-learn AgglomerativeClustering).
6. Performans Değerlendirmesi.

Verinin Yüklmesi ve Hazırlanması

Veri, 'pandas.read_csv()' komutu ile yüklenir.

Bu aşamada, gözetimsiz öğrenme kuralına uygun olarak, kullanılacak özellikler (X) ve kontrol için ayrılacak hedef sütunu (y) ayrılır.

X, 7 sayısal özelliği içerir; y ise Kama, Rosa, Canadian sınıflarını içerir.

Ön İşleme: Ölçeklendirmenin Önemi

Hiyerarşik Kümeleme, mesafe bazlı bir algoritmadır. Bu nedenle, özelliklerin farklı ölçeklerde olması, büyük ölçekli özelliklerin sonucu domine etmesine neden olur.

Tüm 7 özellik sayısal olduğundan, 'StandardScaler' ile ölçeklendirme yapılır. Bu işlem, tüm özelliklerin ortalamasını 0 ve standart sapmasını 1 yapar, böylece mesafe hesaplamaları adil hale gelir.

SciPy Kütüphanesinin Rolü

Hiyerarşik kümeleme analizi, genellikle iki aşamalıdır. Scikit-learn, küme etiketlerini (`y_pred`) almak için kullanılırken, birleşme matrisini (`Z`) ve görsel çıktısı (Dendrogram) oluşturmak için `'scipy.cluster.hierarchy'` kütüphanesi kullanılır.

Linkage (Z) Matrisinin Oluşturulması

'linkage()' fonksiyonu kullanılır: `Z = linkage(X_scaled, method='ward')`.
Bu komut, ölçeklendirilmiş veriyi ve seçilen Ward bağlantı kriterini kullanarak tüm birleşme adımlarını hesaplar.
Z matrisi, hangi örneklerin birleştiğini, hangi 'mesafede' birleştiklerini ve oluşan yeni küme boyutlarını içerir.

Dendrogram Uygulaması: Görselleştirme

Dendrogram, 'scipy.cluster.hierarchy' içindeki 'dendrogram()' fonksiyonu çağrılarak çizdirilir.

İlk adımda, geniş bir çizim alanı ayarlanır: 'plt.figure(figsize=(10, 7))'.

Bu görselleştirme, algoritmanın veride bulduğu doğal gruplamaları anlamamanın ana yoludur.



Büyük Veri Setleri İçin Kısaltma

Seeds veri setinde 210 örneklem vardır. Ağacın tamamını (210 yaprak) çizmek, grafiği okunaksız hale getirir.

Bu nedenle 'truncate_mode' parametresi kullanılır: 'dendrogram(Z, truncate_mode='level', p=3)'.
'truncate_mode='level', p=3' ayarı, ağacın sadece en üst 3 birleşme seviyesini göstermesini sağlar, bu da hiyerarşinin tepesini görmemizi kolaylaştırır.

Dendrogram Nasıl Okunur? (Y Eksen)

Dikey Eksen ('plt.ylabel('Distance)'), küme birleşmesinin gerçekleştiği mesafeyi gösterir.

Bu mesafe, kullanılan Linkage Kriterine (örneğin Ward'a) bağlı olarak hesaplanan dissimilarity değeridir.

İki kümeyi birleştiren dikey çizgi ne kadar uzunsa, o iki küme başlangıçta birbirinden o kadar farklı veya uzaktı demektir.

Optimal Küme Sayısının Belirlenmesi

En uzun dikey çizgileri (yani en büyük dissimilarity sıçramalarını) kesen yatay bir çizgi çizilerek optimal küme sayısı belirlenir.
Çizilen bu yatay çizginin kestiği dikey çizgiler (kollar) küme sayısını verir.
Seeds veri setinde, bu analiz genellikle 3 kümeyi (muhtemelen iki yakın küme ve bir uzak küme) gösterecektir.



Dendrogram analizi sonucunda K sayısını belirledikten sonra, 'sklearn.cluster' içindeki 'AgglomerativeClustering' sınıfı çağrılır. Bu sınıf, artık birleştirme sürecinin hangi noktada duracağını bilmektedir (n_clusters parametresi).

Model Parametrelerinin Tanımlanması

Model şu şekilde tanımlanır: 'model = AgglomerativeClustering(n_clusters=3, linkage='ward')'.

'n_clusters=3': Seeds veri setindeki beklentimize ve Dendrogram analizine uygun olarak 3 küme hedeflediğimizi belirtir.

'linkage='ward': Analizde kullandığımız Bağlantı Kriterini tekrar belirtir.

Küme Etiketlerinin Üretilmesi

Model, ölçeklendirilmiş veri (X_scaled) üzerinde eğitilir ve küme etiketleri tahmin edilir:

```
'y_pred' = model.fit_predict(X_scaled)'
```

'y_pred', her veri noktasına (örnekleme) atanan küme etiketlerini (örneğin 0, 1 veya 2) içeren bir dizidir.

Değerlendirme: İçsel Metrikler

Kümeleme, gözetimsiz bir görev olduğundan, modelin kalitesini ölçmek için içsel (internal) metrikler kullanılır.

En yaygın kullanılan metrik Silhouette Score'dur.

Bu metrik, kümelerin ne kadar iyi (yoğun ve ayrıışmış) olduğunu ölçer: yüksek skor, daha iyi tanımlanmış kümeler anlamına gelir.



Silhouette Score Detayı

Silhouette Score, her nokta için iki değeri karşılaştırır:

a (Uyum): Noktanın kendi kümesindeki diğer noktalara ortalama mesafesi (düşük olmalı).

b (Ayrışma): Noktanın en yakın komşu kümesindeki noktalara ortalama mesafesi (yüksek olmalı).

Score = $(b - a) / \max(a, b)$. Değer aralığı -1 ile +1'dir.

Dışsal Değerlendirme (External Validation)

Bu tür veri setlerinde (gerçek etiketlerimizin olduğu), modelimizin bulduğu etiketlerin (y_{pred}) gerçek etiketlerle (y_{true} - Kama, Rosa, Canadian) ne kadar örtüştüğünü değerlendirmek önemlidir.

Bu değerlendirme, modelin veri içindeki 'gerçek' biyolojik yapıyı ne kadar iyi yakaladığını gösterir.

Kullanılan metrikler: Adjusted Rand Index ve Homogeneity Score.

Adjusted Rand Index (ARI)

ARI, modelin bulduğu iki etiket setinin rastgele şanstan daha iyi ne kadar benzer olduğunu ölçer.

Değer aralığı genellikle -1 (kötü eşleşme) ile $+1$ (mükemmel eşleşme) arasındadır.

Kümeleme performansını, etiketleri yeniden adlandırma (label permutation) etkisine karşı duyarsız kılarak değerlendirir.



Homogeneity Score

Homogeneity (Homojenlik) metrikleri, 'her kümenin sadece tek bir gerçek sınıfın üyelerini içerip içermediğini' ölçer. Yani, modelin oluşturduğu kümeler ne kadar 'saf' (tek tip) ise, skor o kadar yüksek çıkar. Bu skor, Entropy kavramına dayanır ve 0 ile 1 arasında değer alır (1 mükemmel homojenliktir).

Optimizasyon ve Hiperparametre Ayarı

Hiyerarşik kümelemede temel hiperparametre, Bağlantı Kriteri seçimidir (Single, Complete, Average, Ward).

Seçilen kriter, Dendrogramın şeklini ve dolayısıyla belirlenecek optimal küme sayısını etkiler.

Farklı kriterler kullanarak aynı veri setinde birden fazla Dendrogram çizmek, verinin yapısı hakkında derinlemesine bilgi sağlar.



Boyut İndirgeme ve Görselleştirme

Seeds veri seti 7 boyutludur. İnsan gözü bu boyutta desenleri algılayamaz. Bulunan küme etiketlerini (y_{pred}) görselleştirmek için, verinin boyutunun 2D'ye indirilmesi gerekir.

Temel Bileşen Analizi (PCA) veya t-SNE gibi teknikler kullanılarak veriler 2 boyuta indirgenir ve modelin bulduğu etiketlere göre renklendirilmiş saçılma grafiği (scatter plot) çizdirilir.



Hiyerarşik Kümelemenin Avantajları

K sayısının önceden belirlenmesine gerek yoktur, Dendrogram analizi bu kararı destekler.

Tek bir çıktı yerine, tüm olası kümeleme çözümlerinin hiyerarşisini sunar. İç içe geçmiş (nested) veya ağaç benzeri yapıya sahip veriler için (biyoloji, filogenetik) doğal bir uyum sağlar.



Hiyerarşik Kümelemenin Dezavantajları

Hesaplama Karmaşıklığı: Özellikle büyük veri setleri için K-Means'e göre çok daha yavaştır ($O(N^3)$ veya $O(N^2 \log N)$).

Karar Verme Zorluğu: Dendrogramdaki kesme noktasını (optimal K) belirlemek bazen öznel olabilir.

Erken Birleşme Hatası: Birleşmeler geri alınamaz, bu nedenle algoritmanın erken aşamalarında yapılan kötü bir birleşme tüm yapıyı etkileyebilir.



Hiyerarşik kümeleme, genellikle Öklid Mesafesi (Euclidean Distance) kullanılarak uygulanır.

Ancak, verinin yapısına bağlı olarak Manhattan (City Block), Kosinüs Benzerliği (Cosine Similarity) veya Mahalanobis mesafesi gibi farklı metrikler de kullanılabilir.

Örneğin, metrik olarak Kosinüs, metin analizi gibi yüksek boyutlu verilerde daha iyi sonuç verebilir.



Dendrogram: Detaylı Analiz

Agglomerative HC'de, birleşme mesafeleri (Y eksenini) monoton olarak artmalıdır.

Eğer bir birleşme, önceki birleşmelerden daha düşük bir mesafede gerçekleşiyorsa, bir hata veya yanlış bağlantı kriteri kullanılmış demektir (bu, özellikle Ward metodu için geçerli bir kontrol değildir, ancak diğerleri için önemlidir).



Gelişmiş Linkage Kriterleri

Ward, birleşme sonrası varyans artışına odaklanırken, Centroid Linkage (merkez noktası) ve Median Linkage de mevcuttur.

Centroid Linkage, iki kümenin merkezleri arasındaki mesafeyi kullanır. Ancak Centroid ve Median metotları, bazı durumlarda Dendrogramda 'inversiyon' (tersine dönme) yaşayabilir, bu da monotonik olmayan mesafeler demektir.



Pratikte Bağlantı Kriteri Seçimi

Eğer yoğun, kompakt ve küresel kümeler bekleniyorsa: Ward veya Complete Linkage tercih edilir.

Eğer uzun, zincirleme veya doğal sınırları belirsiz kümeler bekleniyorsa: Single Linkage tercih edilebilir.

Ward, Seeds veri seti gibi genel amaçlı bilimsel çalışmalarda genellikle en iyi başlangıç noktasıdır.

Küme Etiketlerinin Eşleştirilmesi

Gözetimsiz modelin ürettiği etiketler (y_{pred}), keyfi olarak 0, 1, 2 olabilir. Gerçek etiketler (y_{true}) ise Kama, Rosa, Canadian'dır.

Küme 0, Kama'ya karşılık gelebileceği gibi, Canadian'a da karşılık gelebilir. Bu etiket eşleşmesi, dışsal değerlendirme metrikleri hesaplanmadan önce (veya bu metrikler tarafından otomatik olarak) ele alınmalıdır.

Dendrogram Kesme Yüksekliği

Optimal küme sayısını belirlemenin bir yolu, Y ekseninde belirli bir 'kesme yüksekliği' (mesafe eşiği) tanımlamaktır.

Bu eşiğin altında kalan tüm birleşmeler dikkate alınır, eşiği geçen birleşmeler ise ayrık küme olarak kabul edilir.

Bu yöntem, analistin belirlediği maksimum 'dissimilarity' (farklılık) düzeyine dayanır.



Dendrogramda Zincirleme Etkisi (Chaining)

Zincirleme (Chaining), özellikle Single Linkage kullanıldığında ortaya çıkan bir sorundur.

Bu durumda, kümeleme, tek bir büyük küme etrafına dizilmiş, uzun, ince 'zincirler' bulur.

Bu, küme şeklinin küresel olmaktan çok, uzun ve bağlantılı olduğu anlamına gelir.



Dendrogramda Yoğunluk Etkisi

Complete Linkage, iki küme arasındaki en büyük mesafeyi minimize etmeye çalıştığı için, sonuçta ortaya çıkan kümeler çok daha sıkı ve kompakttır. Bu, kümenin dış çevresindeki aykırı değerlerin (outliers) ayrı tutulmasına yardımcı olur, ancak kümenin boyutunu küresel bir sınıra zorlar.



Agglomerative Kümelemede Hafıza Yönetimi

Agglomerative HC, N veri noktası için yaklaşık $O(N^2)$ hafıza gerektirir. Bunun nedeni, algoritmanın her adımda birleşmeleri saklaması ve başlangıçta tüm $N \times N$ mesafe matrisini hesaplaması gerekmesidir. Bu, milyonlarca veri noktasında pratik olmayan bir kısıtlamadır.

Divisive Kümeleme Algoritmaları

Divisive algoritmalar teorik olarak daha az kullanılır.

DIANA (Divisive ANALysis) en bilinen divisive algoritmadır. Başlangıçta tüm kümeyi en çok benzemeyen noktalar temelinde bölmeye çalışır.

BIRCH (Balanced Iterative Reducing and Clustering using Hierarchies) ise büyük veri setleri için tasarlanmış bir hibrid çözümdür.



K-Means ile HC Karşılaştırması

HC deterministiktir (tekrarlandığında aynı sonucu verir), K-Means ise başlangıç merkezlerine bağlı olarak farklı sonuçlar verebilir (rastgelelik içerir). HC, tüm hiyerarşiyi saklar ve esnekler. K-Means, küme sayısını sabitler ve genellikle daha hızlıdır. Küme şekli açısından HC, K-Means'ten daha karmaşık şekilleri modelleyebilir.

Ön İşlemede Outlier (Aykırı Değer) Yönetimi

Hiyerarşik Kümeleme, mesafe hesaplamalarına dayandığı için aykırı değerlere karşı hassastır.

Özellikle Complete Linkage ve Single Linkage, aykırı değerlerden güçlü şekilde etkilenebilir.

Uygulama öncesinde aykırı değer tespiti ve temizliği (ya da RobustScaler kullanımı) önerilir.



Seeds Veri Seti: Biyolojik İlişkinin Önemi

Seeds veri setindeki Kama, Rosa ve Canadian buğdayları arasındaki genetik farklılıklar, tohumun geometrik özelliklerine yansır.

Hiyerarşik modelin bulunduğu grupların (örneğin Küme 1 ve Küme 2'nin yakın birleşmesi), biyolojik sınıflandırma (filogenetik) ile uyumlu olması beklenir. Bu uyum, modelin sadece rastgele gruptama yapmadığını, doğal yapıyı keşfettiğini gösterir.



Linkage Matrisi (Z) Yapısı

Z matrisi, her satırın bir birleşme adımını temsil ettiği $N-1$ satırlık bir matristir.
Sütun 1 ve 2: Birleşen iki kümenin veya örneğin indisleri.
Sütun 3: Birleşmenin gerçekleştiği mesafe (dissimilarity).
Sütun 4: Yeni oluşan kümedeki örneklem sayısı.

Dendrogram Etiketleri: Leaf Labels

Dendrogramın altındaki 'yapraklar' (leafs), genellikle bireysel veri noktalarını temsil eder.

Eğer veri seti küçükse, bu yapraklar örneklem numaralarıyla etiketlenebilir. Büyük veri setlerinde, 'truncate_mode' kullanıldığında, yapraklar artık bireysel noktalar değil, birleşmiş küçük kümelerdir ('p' değeri bunu belirler).

Optimal K Seçimi: Elbow Metodu

Her ne kadar Dendrogram ana yöntem olsa da, K-Means'teki Elbow (Dirsek) metodu hiyerarşik kümeleme için de uyarlanabilir. Farklı K değerleri için Silhouette Score veya WCSS (Inertia) değerlerinin değişimini inceleyerek optimal 'K' sayısının bulunduğu noktayı arayabiliriz. Ancak bu, hiyerarşik yapıyı göz ardı ettiği için Dendrogram kadar bilgilendirici değildir.



Küme İçindeki Yoğunluk

Ward'ın Bağlantı Kriteri, birleşmeyi en az WCSS artışıyla gerçekleştirmeyi hedefler.

Bu, Agglomerative Clustering modelini kurduktan sonra bulunan kümelerin, K-Means tarafından bulunan kümelere benzer yoğunluk ve kompaktlığa sahip olacağı anlamına gelir.



Dışsal Değerlendirme Metriği: V-Measure

Homogeneity Score, yalnızca saflığı ölçer.

Completion Score (Tamamlılık) ise, aynı gerçek sınıfa ait tüm veri noktalarının tek bir kümede toplanıp toplanmadığını ölçer.

V-Measure, bu iki metriğin harmonik ortalamasıdır ve dışsal değerlendirmede sıkça kullanılır.



Görselleştirme: Saçılma Grafiği Detayı

PCA/t-SNE ile indirgenmiş 2D grafikte, her nokta modelin atadığı renkte (y_{pred}) çizilir.

Bu görselleştirme, modelin Seeds veri setindeki Kama, Rosa ve Canadian gruplarını ne kadar temiz ayırdığını sezgisel olarak anlamamızı sağlar. Başarılı bir modelde, aynı renkteki noktalar birbirine yakın ve farklı renkteki noktalar ayık olacaktır.

Yüksek Boyutlu Veri Zorlukları

Özellik sayısı arttıkça (yüksek boyut), veri noktaları arasındaki mesafeler daha az anlamlı hale gelir.

Hiyerarşik Kümeleme, özellikle mesafe bazlı olduğu için bu durumdan etkilenir. Çözüm: Boyut indirgeme (PCA) veya önden özellik seçimi yapmak, kümeleme başarısını artırabilir.



Uygulama İpuçları: SciPy ve Matplotlib

Dendrogramın okunabilirliği için figsize ayarı kritik öneme sahiptir. Yatay eksendeki etiketler (yapraklar), veri noktası sayısına göre döndürülebilir veya atlanabilir. Eksen etiketleri ('plt.ylabel('Distance')') ve başlık, analizin anlaşılması için zorunludur.



Hiyerarşik Kümeleme Çözümlerinin Kararlılığı

Büyük veri setlerinde, HC'yi hızlandırmak için verinin bir alt kümesi üzerinde (subsample) çalışılabilir. Ancak bu, Dendrogramın tüm popülasyonu temsil etme yeteneğini azaltabilir. Kümeleme sonuçlarının farklı alt örnekler üzerinde tutarlı olup olmadığını kontrol etmek, model kararlılığını test eder.



Uygulama Alanları: Biyoinformatik

Hiyerarşik Kümeleme, özellikle biyoinformatikte çok popülerdir. Gen ekspresyon verilerinde (mRNA, protein seviyeleri), genlerin hangi koşullar altında benzer davrandığını ve doğal hiyerarşilerini belirlemek için kullanılır. Seeds veri setindeki biyolojik ilişki, bu uygulamaların basitleştirilmiş bir örneğidir.

Uygulama Alanları: Pazar Segmentasyonu

Müşterilerin satın alma davranışlarını veya demografik özelliklerini kümelemek için de kullanılabilir.

HC'nin hiyerarşik yapısı, 'Büyük bir müşteri grubu (Kuşak X) ve bu grubun altındaki iki alt segment (geleneksel ve yenilikçi) gibi iç içe geçmiş segmentasyonları ortaya çıkarmayı sağlar.



Gözetimsiz Modellerin Gerçek Hayat Etkisi

Gözetimsiz modellerin en büyük gücü, analistin bilmediği veya beklemediği yapıları keşfetmesidir.

Hiyerarşik Kümeleme ile elde edilen Dendrogram, veri setindeki doğal yapı hakkında güçlü ve görsel bir içgörü sunar.

Seeds veri setinde de amaç, 'buğday türlerinin' biyolojik ilişkisinin algoritmalar tarafından doğrulanmasıdır.



Agglomerative Clustering Sınıfının Diğer Metotları

Scikit-learn'deki 'AgglomerativeClustering' sınıfı, 'n_clusters' (küme sayısı) yerine 'distance_threshold' (mesafe eşiği) parametresini de kullanabilir. Eğer bu eşik belirlenirse, model bu eşikten daha uzun mesafede birleşen kümeleri ayırarak küme sayısını otomatik olarak belirler. Bu, doğrudan Dendrogram kesme yönteminin kodsallı uygulamasıdır.

Özet: Hiyerarşik Kümelemenin Ana Çıktıları

1. HC, K-Means'in K zorunluluğunu aşar.
2. İki yaklaşım vardır: Agglomerative (Bottom-up) ve Divisive (Top-down).
3. Linkage Kriteri (Ward, Single, Complete) birleşme mesafesini belirler.
4. Temel çıktı Dendrogram'dır ve K'yı belirlemek için kullanılır.
5. Seeds veri setinde biyolojik hiyerarşiyi keşfettik.
6. Performans, Silhouette ve ARI gibi metriklerle değerlendirilir.

Seeds Veri Seti Üzerinde Uygulanan Adımlar

1. Özellikler ölçeklendirildi (StandardScaler).
2. Ward Linkage Matrisi oluşturuldu (SciPy).
3. Dendrogram çizildi ve K=3 belirlendi.
4. AgglomerativeClustering (n_clusters=3, linkage='ward') modeli eğitildi.
5. y_pred etiketleri üretildi ve dışsal doğrulama yapıldı.

DBSCAN, yoğunluk bazlı kümeleme algoritmasıdır ve HC/K-Means'in küresel küme varsayımını ortadan kaldırır.

Kümeleme Ensemble'ları (birden fazla kümeleme modelinin sonuçlarını birleştirmek), daha kararlı ve doğru sonuçlar elde etmek için kullanılan ileri bir tekniktir.

Bu teknikler, Hiyerarşik Kümelemeden alınan çıktıları zenginleştirebilir.



Hiyerarşik Kümeleme

Süleyman **EZDEMİR**

suleyman.ezdemir@giresun.edu.tr

